

# 基于低秩和稀疏表示的高光谱图像的异常检测

杨旭，*IEEE* 学生会员，吴泽斌，*IEEE* 会员，李俊，*IEEE* 会员，Antonio Plaza，*IEEE* 会员，魏志辉

**摘要：**提出了一种基于低秩和稀疏表示的超规格图像（HSIs）异常检测的新方法。提出的方法是基于观察数据中背景和异常的分离。由于背景中的每个像素可以用背景字典近似表示，所有像素的表示系数形成一个低秩矩阵，因此低秩表示被用来对背景部分进行建模。为了更好地描述每个像素的局部表征，在表征系数中加入了诱导稀疏性的正则化项。此外，还采用了一种字典构建策略，以使字典更加稳定和具有鉴别性。然后，通过残差矩阵的响应来确定异常情况。所提算法的一个重要优势是它结合了HSI中的全局和局部结构。实验结果已使用模拟和真实数据集进行。这些实验表明，我们的算法实现了非常有前途的异常检测性能。

**Index Terms**-Anomaly detection, dictionary construction, hyperspectral image (HSI) analysis, lowrank representation (LRR), sparse representation.

## I. 简介

**H**幽灵图像（HSI）传达了有关材料光谱特性的丰富信息。

涵盖特定波长的数百甚至数千个波段[1]。每个高光谱像素的光谱可以被看作是一个矢量，每个条目代表每个光谱带的反射值的辐射度[2]。由于不同的材料通常在以下几个方面反射电磁能量

2015年3月收到稿件10，；2015年6月修订30，；接受2015年9月23日。发表日期2015年11月9日；当前版本日期3月这项9,2016.工作得到了国家自然科学基金61471199和11431015的部分支持，以及中央高校基础研究基金30915012204的部分支持。（通讯作者：吴泽斌。）

Y.Xu和Z. Wei在南京科技大学计算机科学与工程学院，南京210094，中国（电子邮件：xuyangth90@gmail.com）。

Z.Wu在南京科技大学计算机科学与工程学院，南京210094，中国，同时也在埃斯特雷马杜拉大学政治学院计算机与通信技术系高光谱计算实验室，Cáceres E-10003，西班牙（电子邮件：zebin.wu@gmail.com）。

J.Li是中山大学地理与规划学院广东省城市化与地理模拟重点实验室的成员，中国510275,广州。

A.Plaza是埃斯特雷马杜拉大学政治学院计算机和通信技术系高光谱计算实验室的成员，卡塞雷斯，E-10003，西班牙。

本文中一个或多个数字的彩色版本可在网上查阅：<http://ieeexplore.ieee.org>。

数字对象标识符10.1109/TGRS.2015.2493201

不同的和特定的波长，HSI数据适用于目标检测，几年来在许多军事和民用领域都有很大的兴趣[2]-

[5]。目标检测的目标是分离出特定的目标光谱或异常属性。异常检测可以被看作是在没有任何关于目标特征的事先信息的情况下进行的目标检测。

在异常检测中，与相邻背景杂波像素有明显不同的光谱特征的像素被定义为光谱异常。著名的Reed-Xiaoli (RX) 算法[6]是基于背景遵循多变量正态分布的假设。然后，RX检测器使用多变量正态分布的概率密度函数来测量测试像素属于背景的概率。由此产生的广义似然比测试的解决方案变成了输入测试像素的光谱向量与其周围邻居之间的马哈拉诺比斯距离。然而，在真实的高光谱场景中，多变量正态分布对于描述复杂的背景来说过于简单。此外，由于噪声和其他异常像素的存在，估计的协方差矩阵和平均矢量作为背景的一种表现形式可能并不准确。为了克服这一限制，人们提出了一些改进的方法。例如，正则化RX[7]将所有HSI像素估计的协方差矩阵正则化。分段式RX[8]是最近提出的一种方法，使用所有图像像素的聚类。加权RX和基于线性滤波的RX方法是在[9]中提出的，旨在改善背景信息估计。此外，基于核理论的方法，如核-

RX[10], [11]和支持向量数据描述[12], [13]被提出，用于将原始空间扩展到多维特征空间。这些方法可以处理非常高维的数据。此外，最近还提出了一些非基于RX的方法。一个基于随机选择的异常检测器在[14]中被预先发送。通过随机选择有代表性的背景像素并采用足够数量的随机选择，减少了背景统计的污染。鉴别性度量学习异常方法在[15]中描述。它利用稳健的异常度量来提高异常像素和其他背景像素之间的可分离性，使用了判别信息。基于子空间的方法在[16]和[17]中提出。为了捕捉局部光谱变化，[18]中提出了多窗口异常检测。

除了上述方法外,最近,基于表征的方法也获得了很多关注。这些方法假定高光谱特征可以通过使用字典进行表示。通过对表示系数的不同约束,我们可以得到不同的检测器。基于稀疏表示的检测器(SRD)被引入到有监督的高光谱目标检测中[19],[20],并假设每个样本可以由字典中的几个原子表示。

的字典。基于协作代表的检测器

是在[21]中提出的。它基于这样一个概念:背景中的每个像素都可以由其空间邻域近似表示,而异常则不能。该表示法是相邻像素的线性组合,而彩色的这些像素之间的劳动关系通过代表权重向量的 $f_2$ -norm最小化而得到加强。然而,这些方法都没有考虑到所有像素的关联性。

因此,在这些方法中没有考虑到全局信息。

本文提出了一种基于低等级和稀疏表示(LRASR)的新型异常检测方法。与其他基于表示的方法相比,本文提出的方法建立在异常部分和背景部分的分离上,背景信息包含在HSI像素的最低等级表示中。低等级表示法(LRR)[22],

[23]可以用来找到所有像素的最低等级表示。然后,通过原始图像的残差和恢复的背景部分,使用最低等级表示,可以得到异常的部分。通过这种方式,所有HSI像素的关系从全局的角度被描述出来。然后,每个像素系数的局部结构对于更好地表示是非常重要的。在所提出的LRASR中,设计了一个稀疏标准来描述数据集的局部结构,它给出了观察到的数据的准确表示。此外,背景字典对表示能力有很大影响。在异常检测中,字典应该由背景像素组成,并覆盖所有的背景类。因此,我们的方法中提出了一种新的字典构建策略,以使表示更加稳定。

和鉴别性的。因此,本文的主要贡献可以概括为以下几点。

- 1) 据我们所知,这是第一次将LRR用于HSI的异常检测目的。背景信息的特点是表示系数的低等级性,而异常信息则包含在残差中。
- 2) 为了更好地描述每个像素的局部结构,在提出的模型中包含了一个疏散诱导的正则器,从而得到了更准确的表示。
- 3) 词典的构建需要考虑两个因素。一个是字典是由背景像素组成的,另一个是它包含所有的背景类别。

本文的其余部分组织如下。第二节详细描述了拟议的

LRASR检测器。在第三节中,对模拟实验和真实数据实验都进行了描述和分析,随后在第四节中得出结论。

## II. 异常检测的Lrasr

### A. 异常检测的LRR

考虑到 $N$ 个像素组成一个带状HSI  $\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^N \in \mathbb{R}^{B \times N}$

在HSI中,一个异常的像素应该与背景像素不同。此外,背景像素之间通常存在很强的相关性,也就是说,背景像素可以由其他一些背景像素代表。这意味着矩阵 $\mathbf{X}$ 可以被分解为背景部分和异常部分,具体如下。

$$\mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E} \quad (1)$$

其中 $\mathbf{D}\mathbf{S}$ 表示背景部分, $\mathbf{D} = [\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_m]$ 是由背景像素形成的背景字典( $m$ 是字典中的原子总数), $\mathbf{S} = [\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_N]$ 表示表示系数, $\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N]$ 表示对应于异常的剩余部分。这意味着,原始数据可以由背景字典重构的。

问题(1)有许多可行的解决方案。为了解决这个问题,我们需要一些标准来描述矩阵 $\mathbf{S}$ 和 $\mathbf{E}$ 。一方面,只有很小一部分像素属于异常点,这意味着矩阵 $\mathbf{E}$ 是稀疏的。另一方面,每个像素的光谱对应于一种材料(这被称为纯像素)或几种材料的混合物(这被称为混合像素)。由于每种材料的光谱都可以用一个子空间来表示,所以HSI中的所有光谱都可以从多个子空间中提取。因此,系数矩阵 $\mathbf{S}$ 应该给出所有光谱联合的最低等级表示。综上所述,对于矩阵

$\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N]$ , 每个 $\mathbf{x}_i$ 代表第 $i$ 个像素,通过解决以下LRR[22]问题来推断异常情况是合适的。

$$\min_{\mathbf{S}, \mathbf{E}} \text{rank}(\mathbf{S}) + \lambda \|\mathbf{E}\|_{2,1} \quad \text{s.t. } \mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E} \quad (2)$$

其中, $\text{rank}()$ 表示等级函数,参数 $\lambda > 0$ 用于平衡两部分的影响,是 $\|\cdot\|_{2,1}$ 规范,定义为矩阵的列的 $f_2$ 规范之和。

$$\|\mathbf{E}\|_{2,1} = \sum_{i=1}^N \sqrt{\sum_{j=1}^d (\mathbf{E}_{j,i})^2} \quad (3)$$

其中 $\mathbf{E}_{j,i}$ 是 $\mathbf{E}$ 的条目。 $f_{2,1}$ 规范鼓励 $\mathbf{E}$ 的列为零,这就假设腐败是

"特定样本",即一些像素被破坏,而其他像素是干净的。对于对应于第 $i$ 个像素的列向量,较大的幅度意味着该像素的异常程度较高。因此,矩阵 $\mathbf{E}$ 很自然地衡量了异常情况。与[24]中提出的方法不同

我们使用LRR来分离数据，它使用鲁棒主成分分析（RPCA）[25]将原始数据分离为低秩部分和稀疏误差部分。正如[22]中指出的。

RPCA依赖于这样一个假设，即数据位于一个单一的低水平区域。

级子空间。然而，由于混合像素的存在，HSI的像素来自多个子空间。因此，在这种情况下使用RPCA可能不合适。相反，通过选择适当的字典，LRR（被认为是RPCA的概括）可以恢复底层的多个子空间。

下面的凸优化为问题（2）提供了一个很好的替代。

$$\min_{\mathbf{S}, \mathbf{E}} \|\mathbf{S}\|_* + \lambda \|\mathbf{E}\|_{2,1}$$

$$\text{s.t } \mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E} \quad (4)$$

其中表示 $\|\cdot\|_*$ 矩阵核常数（矩阵的正弦值之和）[26]。一旦表示过程结束，第1个频谱 $T(\mathbf{x}_i)$ 的异常情况就可以通过残余矩阵 $\mathbf{E}$ 的响应来确定，如下所示。

$$T(\mathbf{x}_i) = [\mathbf{E}^*]_{:,i2} = ([\mathbf{E}^*])_{j,i}^2 \quad (5)$$

其中 $[\mathbf{E}^*]_{:,i}$ 表示 $\mathbf{E}$ 的\*第 $i$ 列的 $f_2$ 规范。如果它大于一个阈值，那么 $\mathbf{x}_i$ 被称为是一个anomalous pixel.

### B. 稀疏正则化的LRR

正如在[22]中所看到的，低等级标准在捕捉观察到的数据 $\mathbf{X}$ 的全局结构方面具有优越性，然而，每个频谱都有自己的局部结构。对局部结构的描述越准确，对观测数据的表示就越准确。稀疏信号表示法已被证明是许多领域的有力工具[27]，[28]。这种成功主要是由于大多数自然信号可以由少数几个系数来稀疏地表示，这些系数携带着与某个字典或基集有关的最重要的信息[28]。在HSI目标检测中，基于稀疏度的目标检测算法被广泛使用。基本的基于稀疏性的检测器使用[28]中提出的类似稀疏性模型，通过少数训练样本（包括目标和背景样本）来稀疏地表示测试图像，然后，它直接采用重建残差来进行检测。在异常检测阶段，由于大部分样本是背景像素，它们在背景字典方面有一个稀疏的表示。因此，矩阵的稀疏性使我们能够描述局部结构。带有稀疏正则化的模型可以写成如下。

$$\min_{\mathbf{S}, \mathbf{E}} \|\mathbf{S}\|_* + \beta \|\mathbf{S}\|_1 + \lambda \|\mathbf{E}\|_{2,1}$$

$$\text{s.t } \mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E} \quad (6)$$

其中， $\|\cdot\|_1$ 是矩阵的 $f_1$ 规范，即是指矩阵中所有条目的绝对值； $\beta > 0$ 是一个参数，用于权衡低等级性和稀疏性。模型（6）包含了通过低秩属性来处理全局结构，通过稀疏属性来处理局部结构，这导致了对原始数据的更准确表述。因此，残留的然而，解决问题（2）是NP-hard。幸运的是，通过矩阵完成方法[25]，提出了

### 算法 1 LADMAP算法用于LRASR的算法

输入：数据矩阵 $\mathbf{X}$ ，参数 $\beta > 0, \lambda > 0$

初始化： $\mathbf{S}_0 = \mathbf{J}_0 = \mathbf{E}_0 = \mathbf{Y}_{1,0} = \mathbf{Y}$ ,  $\mu_0 = 0.01$ ,

$\mu_{\max} = 10^{10}$ ,  $\rho_0 = 1.1$ ,  $\varepsilon_1 = 10^{-6}$ ,  $\varepsilon_2 = 10^{-2}$ ,  $\eta_1 = \mathbf{D}^2$ ,  $k=0$ .

1: 而  $\|\mathbf{X} - \mathbf{D}\mathbf{S}_k - \mathbf{E}_k\|_F / \|\mathbf{X}\|_F \geq \varepsilon_1$   
 或  $\max(\sqrt{\eta_1} \|\mathbf{S}_k - \mathbf{J}_k\|_F, \|\mathbf{E}_k - \mathbf{E}_{k-1}\|_F) / \|\mathbf{E}_k\|_F \geq \varepsilon_2$  do

2: 更新变量 $\mathbf{S}_{k+1}$ 。

$$\mathbf{S}_{k+1} = \Theta_{\eta_1}(\mu_k \mathbf{S}_{k+1} + \mathbf{D}^T(\mathbf{X} - \mathbf{D}\mathbf{S}_k - \mathbf{E}_{k+1} + \mathbf{Y}_{1,k}/\mu_k) - (\mathbf{S}_k - \mathbf{J}_{k+1} + \mathbf{Y}_{2,k}/\mu_k)/\eta_1)$$

3: 更新变量 $\mathbf{J}_{k+1}$ 。

$$\mathbf{J}_{k+1} = \mathbf{S}_{\beta/\mu_k}(\mathbf{S}_{k+1} + \mathbf{Y}_{2,k}/\mu_k)$$

4: 更新变量 $\mathbf{E}_{k+1}$ 。

$$\mathbf{E}_{k+1} = \Omega_{\lambda/\mu_k}(\mathbf{X} - \mathbf{D}\mathbf{S}_{k+1} + \mathbf{Y}_{1,k}/\mu_k)$$

5: 更新拉格朗日乘数，如下所示。

$$\mathbf{Y}_{1,k+1} = \mathbf{Y}_{1,k} + \mu_k(\mathbf{X} - \mathbf{D}\mathbf{S}_{k+1} - \mathbf{E}_{k+1})$$

$$\mathbf{Y}_{2,k+1} = \mathbf{Y}_{2,k} + \mu_k(\mathbf{S}_{k+1} - \mathbf{J}_{k+1})$$

6: 更新 $\mu$ ，如下所示。

$$\mu = k + 1 \min(\mu_{\max}, \rho \mu_k) \text{ 其中}$$

$$\rho = \begin{cases} \rho_0, & \text{if } \mu_k \max(\sqrt{\eta_1} \|\mathbf{S}_{k+1} - \mathbf{S}_k\|_F, \|\mathbf{J}_{k+1} - \mathbf{J}_k\|_F) / \|\mathbf{X}\|_F \geq \varepsilon_1 \\ 1/\ell, & \text{否则} \end{cases}$$

7: 更新 $k$ :  $k \leftarrow k + 1$

8: 结束，同时

输出：一个最佳解决方案 $(\mathbf{S}_k, \mathbf{J}_k, \mathbf{E}_k)$ 。

矩阵 $\mathbf{E}$ 提供了对异常情况的更好描述。

LRASR问题(6)可以通过流行的交替方向法[22], [29]来解决。然而, 在求解(6)时需要引入两个辅助变量, 而且每次迭代都需要进行昂贵的矩阵反演。因此, 我们采用一种新开发的方法, 即带有自适应惩罚的线性化交替方向法(LADMAP) [30]来解决(6)。

### 算法 基于LRASR的HSI的2异常检测算法

输入：数据矩阵 $\mathbf{X}$ ，参数 $\beta > 0$ ， $\lambda > 0$ ， $K, P$   
 1: 使用 $K$ -means将数据矩阵 $\mathbf{X}$ 分成 $K$ 部分  
 算法，s.t.  
 $\mathbf{X} = \sum_{i=1, \dots, K} \mathbf{X} \mathbf{X}^T \mathbf{X} \mathbf{X}^T \mathbf{X} = \mathbf{0}$ ， $\mathbf{0} \leq \mathbf{X} \leq \mathbf{1}$ ， $i, j = 1, \dots, K$ ，  
 用 $N_i$ 表示 $\mathbf{X}$ 中的像素数 $i$ ， $\mathbf{D} = \mathbf{0}$ 。  
 2: 对于 $i \in \{1, \dots, K\}$ ：  
 1 $K$   
 2.1: 如果 $N_i < P$   
 Skip and go to Step 2;  
 2.2 平均值：计算平均向量 $\boldsymbol{\mu}$ 和协方差矩阵。  
 数据  $\{\mathbf{x}_j | \mathbf{x}_j \in \mathbf{X}, i, j = 1, \dots, N_i\}$ 。  
 2.3：计算预检测结果。  
 $PD(\mathbf{x}_j) = (\mathbf{x}_j - \boldsymbol{\mu})^T (\mathbf{x}_j - \boldsymbol{\mu})$ ， $j = 1, 2, \dots, N_i$   
 2.4: 选择 $P$ 像素 $\mathbf{D} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_P]$   
 $\{\mathbf{x}_j | \mathbf{x}_j \in \mathbf{X}, j = 1, \dots, N_i\}$ ，s. 在  
 $PD(\mathbf{x}_i) < PD(\mathbf{x}_j)$ ， $\mathbf{x}_i \in \mathbf{D}^i$ ， $\mathbf{x}_j \in \{\mathbf{x}_j | \mathbf{x}_j \in \mathbf{X}, i, j = 1, \dots, N_i\} / \mathbf{D}^i$   
 2.5:  $\mathbf{D} = \mathbf{D} \cup \mathbf{D}^i$   
 结束  
 3、用算法解决以下问题 1，

$$\min_{\mathbf{S}, \mathbf{E}} \|\mathbf{S}\|_F + \beta \|\mathbf{S}\|_1 + \lambda \|\mathbf{E}\|_{2,1}$$

$$\text{s.t. } \mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E}$$

并获得最优解  $(\mathbf{S}^*, \mathbf{E}^*)$ 。

$$4: \text{计算 } T(\mathbf{x}_i) = [\mathbf{E}^*]_{i,2} = \sqrt{([\mathbf{E}^*]_{i,1})^2},$$

$$i=1, 2, \dots, N$$

输出。异常检测图。

To make the objective function separable, we introduce an auxiliary variable  $\mathbf{J}$  which satisfies  $\mathbf{S} = \mathbf{J}$ ; then, we can replace the second term  $\|\mathbf{S}\|_1$  in the objective function with  $\|\mathbf{J}\|_1$ . 因此，原问题 (6) 可以转换为以下内容问题。

$$\min_{\mathbf{S}, \mathbf{E}} \|\mathbf{S}\|_F + \beta \|\mathbf{J}\|_1 + \lambda \|\mathbf{E}\|_{2,1}$$

$$\text{s.t. } \mathbf{X} = \mathbf{D}\mathbf{S} + \mathbf{E}, \mathbf{S} = \mathbf{J}$$

问题 (7) 的增强的拉格朗日函数为

$$\begin{aligned} L(\mathbf{S}, \mathbf{J}, \mathbf{E}, \mathbf{Y}_1, \mathbf{Y}_2, \mu) &= \|\mathbf{S}\|_F + \beta \|\mathbf{J}\|_1 + \lambda \|\mathbf{E}\|_{2,1} + \langle \mathbf{Y}_1, \mathbf{X} - \mathbf{D}\mathbf{S} - \mathbf{E} \rangle \\ &+ \langle \mathbf{Y}_2, \mathbf{S} - \mathbf{J} \rangle + \frac{\mu}{2} \|\mathbf{X} - \mathbf{D}\mathbf{S} - \mathbf{E}\|_F^2 + \frac{\mu}{2} \|\mathbf{S} - \mathbf{J}\|_F^2 \\ &= \|\mathbf{S}\|_F + \beta \|\mathbf{J}\|_1 + \lambda \|\mathbf{E}\|_{2,1} \\ &+ f(\mathbf{S}, \mathbf{J}, \mathbf{E}, \mathbf{Y}_1, \mathbf{Y}_2, \mu) - \frac{1}{2} \|\mathbf{Y}_1\|_F^2 + \frac{1}{2} \|\mathbf{Y}_2\|_F^2 \end{aligned}$$

其中  $(\mathbf{Y}_1, \mathbf{Y}_2)$  是拉格朗日乘数  $\mu > 0$  是惩罚参数，以及

$$\begin{aligned} f(\mathbf{S}, \mathbf{J}, \mathbf{E}, \mathbf{Y}_1, \mathbf{Y}_2, \mu) &= \frac{\mu}{2} \|\mathbf{X} - \mathbf{D}\mathbf{S} - \mathbf{E} + \mathbf{Y}_1 / \mu + \mathbf{S} - \mathbf{J} + \mathbf{Y}_2 / \mu\|_F^2 \\ &- \frac{1}{2} \|\mathbf{Y}_1\|_F^2 + \frac{1}{2} \|\mathbf{Y}_2\|_F^2 \end{aligned}$$

LADMAP是一个多变量的优化问题，可以通过在其他变量固定的情况下最小化 $L$ 来交替更新一个变量来解决。假设我们处于第 $k$ 次迭代，问题可分为以下几个子问题。

1) 固定 $\mathbf{J}$ 和 $\mathbf{E}$ ，并更新 $\mathbf{S}$ ；目标函数可以写成如下。

$$\begin{aligned} \mathbf{S}_{k+1} &= \arg \min_{\mathbf{S}} \|\mathbf{S}\|_F + \langle \nabla_{\mathbf{S}} f(\mathbf{S}_k, \mathbf{J}_k, \mathbf{E}_k, \mathbf{Y}_{1,k}, \mathbf{Y}_{2,k}, \mu_k), \mathbf{S} - \mathbf{S}_k \rangle \\ &+ \frac{\eta_1 \mu_k}{2} \|\mathbf{S} - \mathbf{S}_{kF}\|_F^2 \\ &= \arg \min_{\mathbf{S}} \|\mathbf{S}\|_F + \frac{\eta_1 \mu_k}{2} \|\mathbf{S} - \mathbf{S}_{k+1} - \mathbf{D}^T (\mathbf{X} - \mathbf{D}\mathbf{S}_k - \mathbf{E} + \mathbf{Y}_{1,k} / \mu_k) + (\mathbf{S}_k - \mathbf{J}_k + \mathbf{Y}_{2,k} / \mu_k) / \eta_1\|_F^2 \end{aligned} \quad (10)$$

其中二次项 $f$ 被其一阶的

在以前的迭代中进行近似，然后加入一个近似项[30]

。 $\nabla_{\mathbf{S}} f$ 是 $f$ 的偏微分。

关于 $\mathbf{S}$ ， $\eta_1 = \mathbf{D}^T$ 。  
 2) 固定 $\mathbf{S}$ 和 $\mathbf{E}$ ，并更新 $\mathbf{J}$ ；目标函数可以是

$$\mathbf{J}_{k+1} = \arg \min_{\mathbf{J}} \beta \|\mathbf{J}\|_1 + \frac{\mu_k}{2} \|\mathbf{S}_{k+1} - \mathbf{J} + \mathbf{Y}_{2,k} / \mu_k\|_F^2 \quad (11)$$

3) 固定 $\mathbf{S}$ 和 $\mathbf{J}$ ，并更新 $\mathbf{E}$ ；目标函数可以写成如下。

$$\begin{aligned} \mathbf{E}_{k+1} &= \arg \min_{\mathbf{E}} \lambda \|\mathbf{E}\|_{2,1} + \frac{\mu_k}{2} \|\mathbf{X} - \mathbf{D}\mathbf{S} - \mathbf{E} + \mathbf{Y}_1 / \mu_k\|_F^2 \\ &- \langle \mathbf{Y}_2, \mathbf{S} - \mathbf{J} \rangle \end{aligned}$$

该解决方案在算法中概述1。


在算法中， $\Theta_1$ 、 $\mathbf{S}$ 和 $\Omega$ 是奇异值阈值。

ing [31], shrinkage [29], and  $f_{2,1}$  minimization operator [22], respectively. 这里，更新 $\mathbf{S}$ 、 $\mathbf{J}$ 和 $\mathbf{E}$ 的顺序可以改变。

### C. 词典 $\mathbf{D}$ 的构建

在上述算法中，字典 $\mathbf{D}$ 扮演了一个重要的角色。

在检测异常情况中起重要作用。在目标检测问题的稀疏表示中，字典由背景字典和目标字典组成，其中是应该知道的。然而，在出现异常的情况下检测，字典是事先不知道的，应该尽可能地代表背景信息。构建字典的一种方法是直接使用原始数据 $\mathbf{X}$ 。虽然原始数据 $\mathbf{X}$ 包含异常点，但异常像素的数量非常少，可以忽略不计。在表示过程中。然而，计算的负担




图：模拟1的数据集。(a)整个场景的假彩色图像，(b)检测区域的假彩色图像，和(c)地面实况图。

是非常大的，因为该算法涉及一个大小为 $M$   $M$ 的矩阵的奇异值分解，其中 $M$ 是原子的数量。另一种方法是从HSI中随机选择一些像素来形成字典。通过这种方式，原子数可以减少。然而，字典应该涵盖所有的地面材料类别，除了异常情况。幸运的是，在HSI中，大部分场景都被几种主要材料所覆盖，所以像素更有可能属于这些主要材料而不是其他。如果我们通过随机选择像素来构建字典，选择属于主要材料的像素的概率非常高，所以构建的字典将由主要材料的像素组成，而一些与其他不太相关的材料的样本将被忽略。因此，对应于具有较少代表性样本的材料的像素将被检测为异常点。

在本文中，采用了一种新的字典构建策略。首先，使用 $K$ -means将所有的像素分为 $K$ 个集群 $\mathbf{X}=\mathbf{X}^1, \mathbf{X}^2, \dots, \mathbf{X}^K$ 。在 $K$ -means算法中使用了欧几里德距离。 $K$ 应该大于为了确保 $K$ 集群覆盖所有的地面材料，我们采用了一个预测性的策略。由于原子应该是一个背景像素，为了选择每个簇中的背景像素，我们采用了一个预知策略。与RX算法类似，测试像素与每个簇中的本地背景平均值之间的马哈拉诺比斯距离的平方被计算。RX检测器假设检测结果的数值越高，像素就越可能是异常的。然而，嘈杂的像素或对应稀有材料的像素可以被检测为异常值，因为它们在HSI中更不常见。

另一方面，具有小的预测值的像素是具有确定性的背景像素。因此，选择给出最小Mahalanobis距离的 $P$ 像素来生成字典中的原子。如果像素的总数在



图：第一个2.真实世界的数据集。(a) 探测区域的假彩色图像和(b)地面实况图。

簇小于 $P$ ，这个簇可以被跳过，因为我们设置的 $K$ 大于地面材料类的实际数量。


基于LRASR的HSI的异常检测算法，使用聚类字典的算法概述如下 2.

III. 实验结果

A. 数据集描述

在本文中，模拟和真实的高光谱数据集都被用来评估我们的方法。模拟数据是在真实的HSI数据集的基础上产生的。它是由美国加州圣地亚哥上空的机载可见光/红外成像光谱仪收集的。空间分辨率为3.5每像素米。该图像有24个光谱通道，波长范围从到370纳米2510。在去除对应于水吸收区域、低信噪比和不良波段（1-6、33-35、94-97、107-113、153-166和221-224）的波段后，可186获得实验中保留了数据的波段。如图1（a）所示，整个数据集的大小为400×400。从这个





图：第二个3.真实世界的数据集。(a)整个图像的假彩色图像，(b)检测区域的假彩色图像，和(c)地面实况图。






图4.LRASR使用不同字典取得的检测结果的二维图。接近红色的颜色表明这些像素是异常的，而接近蓝色的颜色则表明这些像素属于背景。结果显示了使用 (a) 我们的字典和 (b) 随机字典的结果。



图：使用不同字典的模拟数据集的ROC5.曲线。

高光谱数据集，选择一个像素100100大小的区域来形成模拟数据。异常像素是通过目标植入法[32]模拟的。基于线性混合模型，一个合成的子像素异常目标与



图：MSE与endmembers数量的关系图6。

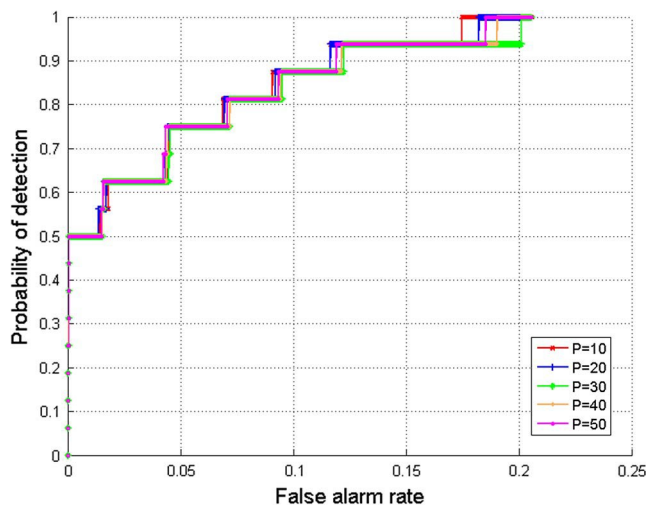

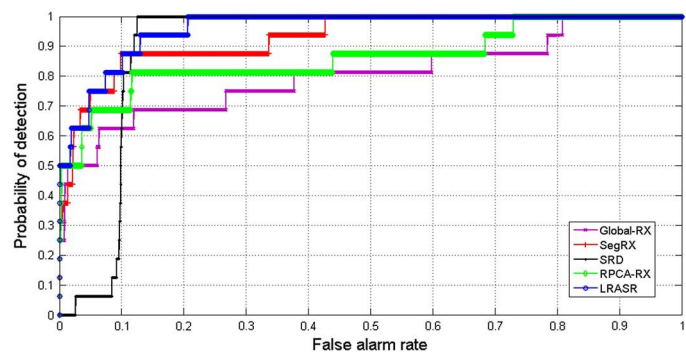


图7在不同的 $P$ 值下，模拟数据集获得的ROC曲线。



图：不同方法对模拟数据集的检测结果的二维8.图。(a) Global-RX, (b) SegRX, (c) SRD, (d) RPCA-RX, 和(e) LRASR。



图：对模拟数据集采用不同方法得到的ROC9.曲线。

表一  
图中7报告的检测器的AUC值。

Algorithm	Global-RX	SegRX	SRD	RPCA-RX	LRASR
AUC	0.8050	0.9283	0.9029	0.8612	<b>0.9597</b>

谱系 $\mathbf{z}$ 和指定的丰度分数 $f$ 是通过在谱系 $\mathbf{b}$ 的背景的特定像素中分次植入所需的异常点而产生的，如下所示[33]。

$$\mathbf{z} = \mathbf{f} \cdot \mathbf{t} + (1 - f) \cdot \mathbf{b}. \tag{13}$$

在图像中，有16个异常目标被植入了。这些异常点分布在四行和四列。不同行的丰度分数 $f$ 分别为0.05、0.1、0.2和0.4，对同一行的异常点保持不变。异常光谱 $\mathbf{t}$ 是在整个图像的选定场景之外选择的，同样的异常光谱 $\mathbf{t}$ 被应用于16个目标像素。它对应于整个场景的左中部的平面。模拟实验中使用的图像场景如图1(b)所示，图1(c)显示了异常点的地面实况图。

用于真实世界检测的第一个数据也是圣地亚哥图像的一部分。场景的左上角100 × 100被选为测试图像。该场景主要由不同屋顶的建筑物、不同材料的停车坪、机场跑道和少量的植被组成。空中飞机是要检测的异常现象。图2(a)和(b)分别显示了假彩色图像和地面实况图。有57个像素被选为异常点，由飞机主体的全像素异常点和地面真实图组成。

飞机边缘的亚像素目标。在这个场景中，与模拟数据集相比，异常情况是很大的。

在真实世界实验中使用的第二个数据集是一个从飞机平台上获得的HYDICE高光谱数据集。它涵盖了一个城市区域，包括一个植被区、一个建筑区和几条道路，包括一些车辆。该图像的光谱分辨率为纳米10，空间分辨率为1米。低信噪比和水汽吸收带（1-4、76、87、101-111、136-153和198-


210）被消除，从而保留了这些带162。整个数据集的大小为

307307个像素，如图3（a）所示。然而，根据地面实况，异常目标是嵌入场景最右上方不同背景中的汽车和屋顶。因此，所考虑的子场景由覆盖这一区域的像素组成。图3(b)和(c)中分别显示了颜色表示和地面实况图。21个异常的目标像素是城市场景中不同大小的车辆。

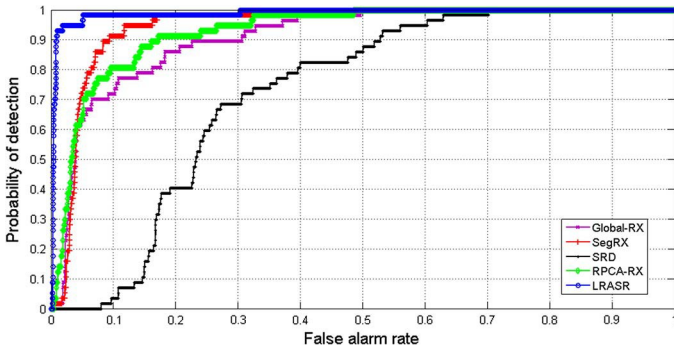
B. 探测性能

首先，我们说明了我们的方法所构建的字典的效果。在我们的字典构建步骤中， $\mathbf{K}$ 和 $\mathbf{P}$ 分别被设置为15和20。我们将我们的方法与另一种使用不同字典的方法进行比较。在该方法中，字典中的所有原子都是从整个图像中随机选择的。为了进行公平的比较，原子的数量被设定为300。图4(a)和(b)中显示了两种方法获得的检测结果的二维图。两张图中的异常情况都很明显。然而，在使用随机字典的方法的结果中，场景最右下角的许多像素尽管没有异常，却表现出很高的检测值。这表明，随机字典不能避免存在噪声像素或对应于罕见材料的像素被检测为异常。为了进行数字比较，构建了接收者操作特征（ROC）曲线，它是不同检测方法的经典比较测量方法[2]，[34]。目标检测率和误报率是通过一定的分割阈值计算出来的。对于每个目标检测器的结果，可以改变分割阈值，以获得每个目标检测器的目标检测率和误报率组，这可以用来绘制ROC曲线。一个更好的检测器会位于最左上角附近，并导致曲线下的面积更大[2]。图为5ROC





图：不同方法对真实的圣地亚哥数据集的检测结果的二维图。(a) Global-RX, (b) SegRX, (c) SRD, (d) RPCA-RX, and (e) LRASR.



图：对于真实的圣地亚哥数据集，用不同方法得到的ROC曲线。

表二  
图中9报告的检测器的AUC。

Algorithm	Global-RX	SegRX	SRD	RPCA-RX	LRASR
AUC	0.9090	0.9446	0.7234	0.9288	<b>0.9882</b>

应用两种考虑的方法后得到的曲线。可以看出，使用我们的字典的方法可以取得更好的结果，这是预期的，因为我们的字典可以覆盖大部分的背景材料，从而提供更强大和可靠的结果。

聚类的数量应该大于地面材料的实际数量，但是这个数量很难预先知道。因此，HySime[35]算法被用来估计能够代表真实地面材料的成员数量。HySime估计信号和噪声的相关矩阵，然后选择在最小均方误差（MSE）意义上最能代表信号子空间的特征值子集。图显示6了所考虑的三个数据集的MSE与endmembers数量的关系。从图6中，我们可以看到，当endmembers的数量大于10时，三个数据集的MSE值都很小。因此，我们在实验中根据经验15设定 $K=15$ 。然后，我们比较了使用不同的 $P$ 值得到的结果几乎相同。因此，我们的方法对 $P$ 是稳健的。为了简单起见，在20我们的实验中， $P$ 被设定为。

接下来，我们评估了我们提出的LRASR检测器的检测性能，将其与传统的全局RX、基于分割的RX（SegRX）检测器、SRD和RPCA-RX进行比较。对于SegRX，首先对整个数据进行K-means聚类，将数据分成几个聚类。然后，在每个聚类中使用RX来检测异常情况。

SegRX中的聚类数量是根据经验设定的。在我们的实验中，RPCA-RX和SRD的重组参数被优化。经过广泛的搜索，SRD的窗口大小参数（ $w_{out}$ ,  $w_{in}$ ）被设定为（15, 7）。所有比较算法的检测结果的二维图

图8(a)-


(e)所示。从这些图中，我们可以看出，所有的方法（除了SRD）都可以区分高丰度分数像素的背景和异常情况。所提出的LRASR也能对低丰度分数的像素提供一个明确的区分。图中显示9了模拟数据集的ROC曲线。图中一个重要的观察结果是8SegRX优于全局RX和RPCA-RX。与SegRX相比，拟议的LRASR在低误报率下表现出稍低的检测概率（当误报率为0.0330.047）。相比之下对SRD来说，它表现出较低检测概率，当误报率为0.1250.2；然而，就整体检测性能而言，提议的LRASR是最好的方法。此外，我们还计算了ROC下的面积

曲线（AUC）来评估这些方法的性能。结果显示在表I中。拟议的LRASR达到了预期的最高分。它比第二高的SegRX高0.03分。比其他测试方法的改进是由于我们提出的LRASR在噪声像素的抑制和弱的异常检测方面表现得更好。


对于真实的圣地亚哥数据集实验，图10(a)-(e)显示了获得的检测结果的二维图。从该图中可以看出，所提出的LRASR给出了一张异常情况明显的地图。为了说明问题，所有方法的ROC曲线都显示在图11中。拟议的LRASR在所有的误报率值中都达到了最高的检测概率。表II中提供了AUC分数。拟议的LRASR达到的分数是比SegRX高0.04，这是一个明显的改进。这证实了所提出的方法可以胜过传统的检测器。

对于真实的城市数据集，所获得的检测结果的二维图如图12 (a) -

(e)所示。图12(e)中的异常点比较明显，少数非异常像素的检测值较高。ROC曲线和AUC分数也分别显示在图13和表III中。尽管当误报率从0.012时，基于表征的SRD获得了更高的检测概率，但在所有检测器中，0.051,提议的LRASR获得了最高的AUC分数。因此，可以得出结论，LRASR



图：不同方法对真实城市数据集的检测结果的二维12.图。(a) Global-RX, (b) SegRX, (c) SRD, (d) RPCA-RX, 和(e) LRASR。




图：不同方法对真实城市数据集获得的ROC13.曲线。

表三  
图中报告的检测器的AUC。 11

Algorithm	Global-RX	SegRX	SRD	RPCA-RX	LRASR
AUC	0.8504	0.8978	0.8928	0.8564	<b>0.9220</b>


表四  
所有实验的执行时间（秒）。 11

	Global-RX	SegRX	SRD	RPCA-RX	LRASR
Simulated data	0.28	8.45	7.13	19.27	169.06
Real San Diego data	0.27	2.67	5.81	22.41	162.49
Real urban data	0.2	2.41	4.56	9.37	132.17




图：模拟数据集的 $\beta$ 和 $\lambda$ 的联合14.考虑。

是一种很有前途的检测HSI中异常像素的方法。  
上述所有方法的计算成本也得到了比较。详细结果见



图：对圣地亚哥真实数据集的 $\beta$ 和 $\lambda$ 的联合15.考虑。



图：对真实城市数据集的 $\beta$ 和 $\lambda$ 的联合16.考虑。

表四。算法在一台装有64b四核英特尔至强CPU 3.33-GHz处理器的计算机上进行了测试，7.结果显示我们的方法确实比其他方法花费更多的计算时间。由于我们的算法需要数百次的迭代才能收敛，因此所提出的方法的计算成本是我们未来发展中需要解决的一个重要问题。

C. 对正则化参数的敏感度

建议的方法涉及两个正则化参数： $\beta$ 和 $\lambda$ 。

通过最大后验 (MAP) 估计问题来计算它们。为了提高计算效率,我们在本文中没有使用鲁棒估计方法。图14-16显示了共同考虑两个正则化参数时获得的性能。 $\beta$ 选自 $\{0.001, 30.01, 0.1, 0.5, 1.2, \dots\}$ , 而 $\lambda$ 从 $\{0.001, 0.01, 0.05, 0.1, 0.2, 0.3, 0.4, 0.5\}$ 。它显示,对于圣地亚哥的数据集,LRASR对 $\beta$ 很敏感。对于模拟数据集和第二个真实世界的数据集,当 $\lambda$ 大于0.5时,它可以达到很高的AUC。

当 $\beta, \lambda \in [0.01, 0.1]$ 时,AUC的变化并不明显。为了简单起见,在我们的实验中,我们根据经验对所有考虑的数据集设置了 $\beta=0.1$ 和 $\lambda=0.1$ ,在所有情况下都取得了满意的结果。


#### IV. 结论和未来的研究方向

本文提出了一种基于LRASR的新的异常检测方法。为了估计背景,每个像素都通过背景二象性原子的线性组合来表示。包含背景信息的表示系数矩阵具有低秩特性。为了更准确地描述每个样本的局部结构,加入了一个稀疏的约束条件。由于字典代表了背景信息,我们提出了一种新的方法来构建字典。通过这种方式,字典中的原子更有可能属于背景,而且字典涵盖了场景中所有的地面材料类别。异常情况是由LRASR的残差计算出来的。事实证明,所提出的LRASR提供了比其他方法更好的检测性能。值得未来研究的一个重要方面是拟议方法的计算复杂性。在这方面,我们目前正在开发使用高性能计算架构(如商品图形处理单元)的有效实现方法。


#### 参考文献

- [1] M. Borengasser, W. S. Hungate, and R. Watkins, *Hyperspectral Remote Sensing-Principles and Applications*. Boca Raton, FL, USA: CRC Press, 2008.
- [2] D. Manolakis and G. Shaw, "高光谱图像应用的检测算法", *IEEE 信号过程. Mag.*, pp. 29-43, Jan. 2002.
- [3] D. W. J. Stein 等人, "高光谱图像的异常检测", *IEEE Signal Process. Mag.*, 第19, 58-69页, 1月。2002.
- [4] S. M. Schweizer 和 J. M. F. Moura, "高光谱图像。异常检测中的杂波适应", *IEEE Trans. Inf. Theory*, vol. 46, no. 5, pp. 1855-1871, Aug. 2000.
- [5] L. Zhang, B. Du, and Y. Zhong, "Hybrid detectors based on selective endmembers," *IEEE Trans. Geosci. 遥感*, 第48卷, 第6期, 第2633-2646页, 六月。2010.
- [6] I. S. Reed 和 X. Yu, "具有未知光谱分布的光学图案的自适应多波段CFAR检测", *IEEE Trans. Acoust. Speech Signal Process.* 第38, 1760-1770页, 10月。1990.
- [7] N. M. Nasrabadi, "Regularization for spectral matched filter and RX anomaly detector," in *Proc. SPIE*, vol. pp. 6966, 2008, 1-12.
- [8] S. Matteoli, M. Diani, and G. Corsini, "Proved estimation of local background covariance matrix for anomaly detection in hyperspectral images," *Opt. Eng.*, vol. 49, no. 4, pp. 1-16, 2010.
- [9] Q. Guo et al., "Weighted-RXD and Linear Filter-Based RXD: Improving background statistics estimation for anomaly detection in hyperspectral imagery," *IEEE J. Sel. Topics Appl. Earth Obs. 遥感*, 第7, 2351-2366页, 6月。2014.
- [10] H. Kwon 和 N. M. Nasrabadi, "Kernel RX-algorithm: 高光谱图像的非林耳异常检测器", *IEEE Trans. Geosci. 遥感*, 第43卷, 第2期, 第388-397页, 2005年2月。
- [11] H. Goldberg, H. Kwon, and N. M. Nasrabadi, "Kernel eigenspace separation transform for subspace anomaly detection in hyperspectral imagery," *IEEE Geosci. Remote Sens. Lett.*, vol. 4, no. 4, pp. 581-585, Oct. 2007.
- [12] A. Bannerjee, P. Burlina, and C. Diehl, "A support vector method for anomaly detection in hyperspectral imagery," *IEEE Trans. Geosci. 遥感*, 第44卷, 第2282-2291页, 8月。2006.
- [13] W. Sakla, A. Chan, J. Ji, and A. Sakla, "An SVDD-based algorithm for target detection in hyperspectral imagery," *IEEE Geosci. 遥感. Lett.*, no. 2, pp. 384-388, Mar. 2011.
- [14] B. Du and L. Zhang, "Random-selection-based anomaly detector for hyperspectral imagery," *IEEE Trans. Geosci.* 1578-1589, May 49, 5, 2011.
- [15] B. Du and L. Zhang, "A discriminative metric learning based anomaly detection method," *IEEE Trans. Geosci. 遥感*, 第52卷, 第11期, 第6844-6857页, 11月。2014.
- [16] M. D. Farrell 和 R. M. Mersereau, "On the impact of PCA dimension reduction for hyperspectral detection of difficult targets," *IEEE Geosci. 遥感. Lett.*, no. 2, pp. 192-195, Apr. 2005.
- [17] K. I. Soumekh, "信号子空间内的高光谱异常检测", *IEEE Geosci. 遥感. Lett.*, vol. 3, no. 3, pp. 312-316, Jul. 2006.
- [18] W. Liu 和 C. I. Chang, "Multiple-window anomaly detection for hyperspectral imagery," *IEEE J. Sel. Earth Obs. 遥感*, 第6卷, 第2期, 第644-658页, 2013年4月。
- [19] Y. Chen, N. M. Nasrabadi, and T. D. Tran, "Simultaneous joint sparsity model for target detection in hyperspectral imagery," *IEEE Geosci. 遥感. Lett.*, 第8卷, 第4期, 第676-680, Jul. 2011.
- [20] Y. Chen, N. M. Nasrabadi, and T. D. Tran, "Hyperspectral image classification via kernel sparse representation," in *Proc. IEEE Int. Conf. 图像处理*. 2011年9月, 比利时布鲁塞尔, 第1233-1236页。
- [21] W. Li 和 Q. Du, "Collaborative representation for hyperspectral anomaly detection," *IEEE Trans. Geosci. 遥感*, 第53, 1463-1474页, 2015年3月。
- [22] G. Liu, Z. Lin, and Y. Yu, "Robust subspace segmentation by low-rank representation," in *Proc. Int. Conf. Conf. Mach. Learn.*, 第663-670页, 2010。
- [23] G. Liu 等人, "Robust recovery of subspace structures by low-rank representation," *IEEE Trans. 模式分析. Mach. Intell.* 第35, 171-184页, 1月。2013.
- [24] W. Sun, C. Liu, and J. Li, "Low-rank and sparse matrix decomposition-based anomaly detection for hyperspectral imagery," *J. Appl. Remote Sens.*, vol. 8, no. 1, May 2014, Art. ID 083641.
- [25] E. J. Candès, X. Li, Y. Ma, and J. Wright, "鲁棒性主成分分析?" *J. ACM*, vol. 58, no. 3, pp. 1-39, May 2011.
- [26] M. Fazel, "Matrix rank minimization with applications," Ph.D. dissertation, Dept. Elect. Eng., Stanford Univ., Stanford, CA, USA, 2002.
- [27] A. M. Bruckstein, D. L. Donoho, and M. Elad, "From sparse solutions of systems of equations to sparse modeling of signals and images," *SIAM Rev.*, vol. 51, no. 1, pp. 34-81, Feb.
- [28] J. Wright 等人, "计算机视觉和模式识别的稀疏表示", *Proc. IEEE*, 第98, 1031-1044页, 六月。2010.
- [29] Z. Lin, M. Chen, and Y. Ma, "The augmented Lagrange multiplier method for exact recovery of corrupted low rank matrices," Univ. Illinois Urbana-Champaign, Champaign, IL, USA, UIUC Tech. Rep. UILU-ENG-09-2215, 2009.
- [30] Z. Lin, R. Liu, and Z. Su, "Linearized alternating direction method with adaptive penalty for low rank representation," *Adv. Neural Inf. Process. Syst.*, pp. 612-620, 2011.
- [31] J. F. Cai, E. J. Candès, and Z. Shen, "A singular value thresholding algorithm for matrix completion," *SIAM J. Optim.*, vol. 20, no. 4, pp. 1956-1982, 2010.
- [32] M. S. Stefanou 和 J. P. Kerekes, "评估光谱图像效用的方法", *IEEE Trans. Geosci. 遥感*, 第47, 1698-1706页, 六月。2009.
- [33] S. M. Schweizer 和 J. M. F. Moura, "Efficient detection in hyperspectral imagery," *IEEE Trans. Image Process.*, vol. 10, no. 4, pp. 584-597, Apr. 2001.
- [34] B. Du 和 L. Zhang, "Unsupervised transfer learning for target detection from hyperspectral images," *Neurocomputing*, vol. 120, pp. 72-82, Nov.

- 2013.
- [35] J.M. Bioucas-Dias和J. M. Nascimento, "高光谱子空间识别", *IEEE Trans.Geosci.遥感*, 第46卷, 第8期, 第2435-2445页, 8月。2008.



他的研究兴趣在超光谱图像分类、图像处理和机器学习领域。



他目前是西班牙卡塞雷斯埃斯特雷马杜拉大学政治学院计算机和通信技术系海量计算实验室的访问学者,也是西班牙埃斯特雷马杜拉大学计算机科学和工程学院的副教授。



从2007年到2011年，她是玛丽-居里夫人的重新搜索研究员，在Departamento de Engenharia任职。

居里研究培训网络，涉及12个国家的15个合作伙伴，旨在促进欧洲层面的高光谱成像研究、培训和合作。自2011年以来，她一直是西班牙卡塞雷斯埃斯特雷马杜拉大学政治学院计算机和通信技术系高光谱计算实验室的博士后研究员。目前，她是中国广州中山大学教授。她的研究兴趣包括高光谱图像分类和分割、光谱解混、信号处理和遥感。

李博士一直是一些期刊的审稿人, 包括IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING, IEEE GEOSCIENCE AND REMOTE SENSING, 《模式识别》、《光学工程》、《应用遥感杂志》和《逆向问题与成像》。她获得了2012年IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING的最佳评论员奖。



遥感高光谱图像分析和高性能计算架构上大规模科学问题的有效实现。他曾是12篇博士论文和30多篇硕士论文的指导老师。他是高光谱成像网络的协调员，这是一个欧洲项目，总资金为280万欧元。他撰写了400多篇出版物，包括130篇期刊引文报告期刊论文（82篇在IEEE期刊上），20个图书章节，以及240多篇同行评审的会议论文（94篇在IEEE会议上）。

他为CRC Press/Taylor and

居里行动, 工程小组)、欧洲航天局、比利时科学政策、以色列科学基金会和西班牙科学和创新部的提案评估员。他曾参加过意大利、西班牙和澳大利亚不同大学的终身教职遴选委员会的工作。他已经为50多个不同的期刊审阅了500多份稿件。他目前还担任IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING杂志的主编。



他目前是南京科技大学的教授和博士生导师。他的研究兴趣包括偏微分方程、数学图像处理、多尺度分析、稀疏回复等。