

一种基于低兰克和稀疏矩阵分解的马哈拉诺比斯距离法 用于高光谱异常检测

张玉香，学生会员，IEEE，杜波，高级会员，IEEE，张良培，高级会员，IEEE，王树根，会员，IEEE

摘要

异常检测在高光谱图像(HSI)处理中发挥着越来越重要的作用。传统的异常检测方法主要是从背景中提取知识，利用异常点和背景之间的差异来区分它们。异常污染和反协方差矩阵问题是这些方法的主要困难。低秩和稀疏矩阵分解(LRaSMD)技术可能有潜力解决上述高光谱异常检测问题，因为它可以从背景和异常中提取知识。本文提出了一种基于LRaSMD的高光谱异常检测的Mahalanobis distance方法(LSMAD)。该方法具有以下功能。1)充分利用LRaSMD技术将背景与异常点区分开来；2)利用背景的低秩先验知识来计算背景统计；3)应用Mahalanobis距离差异来检测可能的异常点。在四个恒星上进行了广泛的实验，发现LSMAD比目前最先进的高光谱异常检测方法有更好的检测性能。

Index Terms-Anomaly detection, hyperspectral imagery, low rank, sparse.

I. 简介

超光谱遥感现在是一种有用的、流行的地球观测技术，用于识别地表物质。与传统的全色和多光谱遥感图像相比，超光谱图像(HSI)可以提供几乎连续的光谱数据。

2014年12月收到稿件25；4月和20,20157月修订19, 2015年；2015年9月7日接受。发表日期2015年10月6日；当前版本日期2月
这项24,2016.工作得到了国家基础研究计划(973计划)2011CB707105和2012CB719905资助，国家自然科学基金61471274和41431175资助，湖北省自然科学基金2014CFB193资助，以及中央高校基本科研经费2042014kf0239资助的部分支持。

Y.Zhang和S.

Wang在武汉大学遥感与形成工程学院工作，武汉，430079（电子邮件：zyx_070504@163.com；wangsg@whu.edu.cn）。

B.Du在武汉大学计算机学院，武汉430079，中国（电子邮件：gunspac@163.com）。

L.Zhang在武汉大学测绘与遥感信息工程国家重点实验室工作430079，（电子邮件：zlp62@whu.edu.cn）。

本文中一个或多个数字的彩色版本可在网上查询：<http://ieeexplore.ieee.org>。

数字对象标识符10.1109/TGRS.2015.2479299

由于大多数高光谱光谱仪的光谱分辨率低于10nm[1]-[4]，因此，地表物质的曲线也就不可能被发现。由于具有高光谱分辨率的特点，具有数百甚至数千个光谱段的高光谱遥感图像在目标检测和分类等地面物体识别技术领域具有独特的优势[1], [2], [5]。

目标检测本质上是一个二元分类问题，其目的是将特定的目标像素从不同的背景中分离出来[1]。异常检测是一种无监督的目标检测技术，没有关于目标或背景的先验知识，重点是将不寻常的材料从典型的背景中区分出来[1]。异常通常是指不寻常的观察结果或具有明显不同于同质背景的光谱特征的物体。背景是指与目标像素相比在图像中占优势的非目标像素[5]。然而，有时可能很难获得感兴趣的物体的先验光谱。因此，异常检测方法一直是许多HSI应用中关注的主题[2]。此外，由于在有监督的目标检测中需要解决光谱变化问题[1]，与感兴趣的物体相关的可能光谱的多重性导致了异常检测器的发展和应用。近年来，高光谱异常检测已成为一个蓬勃发展的研究课题，并已成功应用于许多应用领域，如矿产侦察、边境监测、搜索和救援等[1], [2], [4], [5]。

目前的异常检测方法主要是从背景中提取知识，利用异常目标和背景之间的差异来区分它们。根据从背景中提取知识的不同方式，近几十年来，人们提出了大量的异常检测方法。一种方法将背景视为单一类型，并假设整个背景服从高斯正态分布。Reed和Yu[3]提出的RX检测器是这类方法的典型，Schaum[4]后来提出了一个子空间版本，被称为子空间RX(SSRX)。RX和SSRX算法是高光谱异常检测中最广泛使用的方法。然而，这些方法使用一个局部区域或整个图像场景中的所有像素来计算背景统计。因此，背景平均值和协方差矩阵很容易受到异常现象的污染[5]。

[6], 这可能会削弱异常点和背景之间的差异。此外, 还存在反协方差矩阵问题, 这通常会导致不稳定的近似, 特别是当反协方差矩阵是由局部图像估计出来的。Billor 等人[7]提出了阻断式自适应计算高效离群者提名器 (BACON) 异常检测器, 它使用从整个高光谱数据集的子集计算出的稳健统计数据来抑制背景统计变量带来的异常污染。还有其他能够减轻异常现象造成的协方差污染的检测器[8],

[9]。一种方法是在高维特征空间中围绕背景估计一个封闭的超球, 并将位于超球之外的像素视为异常值。局部支持向量数据描述是一种典型的方法。虽然这种方法在同质区域可以合理采用, 但当局部背景包含大的干扰或多类时, 结果往往不稳定[10],

[11]。另一种方法是假设背景图像是低等级的, 而异常情况在残余图像中被保留下来。基于鲁棒主成分分析 (RPCA) 的异常检测器是一个典型的例子, 它的目的是从被稀疏噪声高度破坏的数据中恢复一个低等级矩阵[12]。尽管这些方法可以产生对背景的准确估计, 但它们不能轻易区分异常和噪声[13], [14]。

最近, 研究人员试图从HSI中提取关于背景和异常的知识[15],

[16], 这可能比那些只探索背景信息的方法提供更有价值的信息, 以区分异常与背景。在HSI中, 光谱通常会受到由成像光谱仪的精度限制、大气变化的误差等引起的噪声的干扰。噪声通常可以被建模为相同和独立分布的高斯随机变量[5]。此外, 高光谱图像通常是平滑的, 即相邻的像素通常由类似的材料组成, 并具有类似的光谱特征。由于带间的强关联性, HSI中平滑和连续的背景中的每个光谱向量可以近似地表示为几个基向量 (如endmembers) 的线性组合[17]。因此, 通常假设背景位于某个低维子空间上, 具有低秩属性。另一方面, 异常点只占整个图像场景的一小部分; 因此, 异常点被认为是随机分布的, 具有低概率。换句话说, 它们有一个稀疏的属性。

基于上述分析, 低秩和稀疏矩阵分解 (LRSMD) 技术[18]-

[20], 将矩阵分解为低秩矩阵、稀疏矩阵和噪声矩阵之和, 与高光谱异常检测问题相一致。因此, 将LRSMD技术应用于高光谱异常检测问题, 有价值的信号可以被恢复并从噪声中分离出来, 背景成分也可以从恢复后的信号中进一步分离。近年来, 一些研究人员努力采用LRSMD技术进行高光谱异常检测。基于

Cui 等人[15]用对应的稀疏分量向量的常数给每个像素打分, Sun 等人[16]用对应的稀疏分量向量与稀疏矩阵的平均向量之间的欧氏差距给每个像素打分, 这可以被称为EDLRSMD。然而, 这两个基于LRSMD的异常检测器并没有充分考虑上述HSI的内部特征。1) 它们最关注的是稀疏成分, 而忽略了背景成分, 由于背景成分与稀疏成分相分离, 所以异常污染效应被抑制; 2) 它们利用的是欧氏距离而不是马哈拉诺比斯距离, 事实证明, 当与HSI高斯假设相匹配时, 欧氏距离对异常检测更合理。3) 它们可能会使检测性能变差, 出现更多的误报, 因为检测决策依赖于稀疏分量, 而在稀疏参数的较大值下, 稀疏分量可能包含一些非异常像素。

基于LRSMD技术和高光谱异常检测问题的一致性, 本文提出了一种基于LRSMD的Mahalanobis距离的高光谱异常检测方法 (LSMAD)。所提出的方法同时利用了背景的低秩先验特性和异常点的稀疏特性来获得背景和稀疏成分。它利用背景的低秩先验知识来计算背景统计, 并构建一个基于Mahalanobis距离的异常检测器。这样, LSMAD可以同时缓解异常污染和反协方差矩阵问题, 提高检测性能。尽管LSMAD和基于RPCA的异常检测器都能探索HSI的低秩和稀疏结构, 但它们有内在的不同。基于RPCA的异常检测器试图从原始数据中准确地恢复潜在的低秩背景结构和稀疏的残余误差结构, 即使在存在大量噪声的情况下。残余误差揭示了异常能量, 但也被噪声所污染, 这削弱了检测性能。LSMAD检测器可以通过从原始数据中恢复三个结构来缓解这个问题: 低等级背景结构、稀疏异常结构和噪声结构。也就是说, 在LSMAD中, 异常点和噪声是分开建模的。

本文的其余部分组织如下。在第二节, 介绍了基本的RX算法和LRSMD模型。然后介绍了拟议的LSMAD方法。第三节介绍了所提出的方法与四个HSI的实验结果。最后, 在第四节中得出结论。

II. 基于LRSMD的马哈拉诺比斯距离 异常情况检测的方法

异常检测的目的是将异常材料从背景中区分出来。因此, 一个好的异常检测器能够有效地确定异常物质和背景之间的差异, 并同时抑制背景。抑制背景的关键过程是

是选择一种适当的方法来有效地表示背景。许多异常检测算法, 如基准的RX异常检测器, 使用背景协方差矩阵来表示背景信息。

RX异常检测器是基于这样的观点进行的: 异常目标和背景类, 重新光谱化, 遵循高斯分布, 具有不同的平均向量和相同的协方差矩阵, 其中目标的光谱和背景的协方差是未知的。在RX异常检测器及其变体中, 背景协方差矩阵的倒数被用来测量观察到的测试像素和背景之间的统计差异。这个过程可以被认为是测试像素和具有椭圆分布的背景进行"球化"或"白化", 从而产生相应的测试像素和具有球状分布但中心不同的背景[2]。然后, RX异常检测器可以建立为测试像素和背景在增白空间中的欧几里得距离, 这实际上是原始空间中的马哈拉诺比斯距离。RX异常检测器被指定为

$$D_{(RX)}(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})\boldsymbol{\Gamma}^{-1}(\mathbf{x} - \boldsymbol{\mu})^T \quad (1)$$

其中 $\mathbf{x} = [x_0, x_1, \dots, x_B]$ 是B维高光谱像素矢量; $\boldsymbol{\mu}$ 和 $\boldsymbol{\Gamma}$ 分别是输入背景数据的平均值和协方差矩阵。后面的

局部检测器的地面平均值和协方差矩阵可以从处理窗口计算出来。然而, 由于缺乏用于估计的背景训练样本, 背景协方差矩阵的逆值通常是有等级缺陷和不稳定的[21]。为了简单起见, 可以从整个图像中估计统计变量。因此, 异常像素会污染背景平均值和协方差矩阵。

LSMAD的目的是从整个图像矩阵中获得有代表性的背景, 并计算出一个合适的背景协方差矩阵, 同时抑制异常的影响。然后, 根据对背景的低秩先验知识的探索, 计算出被保留的背景统计数据, 这可以缓解逆协方差矩阵问题。

A. 高光谱图像的LRaSMD模型

LRaSMD模型是由Zhou等人提出的[22]。它假设来自 $m \times n$ 高维数据矩阵的矩阵 \mathbf{D} 被严重的稀疏错误或离群值 $\mathbf{S}^{m \times n}$ 所破坏。在现实世界的应用中, 观测数据经常被噪声所破坏, 这些噪声可能是随机的或确定的。因此, 观察到的数据 \mathbf{D} 可以 $m \times n$ 被建模为

$$\mathbf{D} = \mathbf{L} + \mathbf{S} + \mathbf{N} \quad (2)$$

其中 \mathbf{N} 是噪声项, 通常假定为独立和相同分布的高斯噪声。

空间和光谱维度为 $H \times W \times B$ 的原始HSI数据立方体可以被重新排列为一个大小为 $N \times B$ 的二维矩阵, 其中 B 代表的是 $N \times B$ 的数量。

光谱带; H 和 W 分别是图像场景的高度和宽度; N 代表整个图像场景的总像素数。我们知道, 图像场景通常是连续和平滑的, 即相邻的像素通常由类似的材料组成, 并具有类似的光谱特征。HSI数据中材料的光谱特征是高度相关的, 因此每个光谱向量可以近似地表示为几个基向量的线性组合。背景图像通常被假定为具有低秩属性。另一方面, 由于HSI的空间分辨率较低, HSI数据中感兴趣的异常点通常具有较低的概率, 只占整个图像场景的很小一部分, 这表明异常点的稀疏特性。

基于上述分析, LRaSMD技术与高光谱异常检测问题是一致的。因此, HSI的模型可以写为

$$\mathbf{x} = \mathbf{b} + \mathbf{s} + \mathbf{n} \quad (3)$$

其中 \mathbf{x} 是观察到的HSI, \mathbf{b} 表示背地图像, \mathbf{s} 表示稀疏成分, \mathbf{n} 代表噪声。很明显, 矩阵 \mathbf{B} 是低等级的, 而矩阵 \mathbf{S} 是稀疏的。然后很自然地观察到的矩阵 \mathbf{X} 采用LRaSM D理论, 以获得背景成分 \mathbf{B} 和稀疏成分 \mathbf{S} 。

B. 模型组件的恢复

近年来, 人们提出了许多LRaSMD优化算法, 这些算法集中于开发快速近似和有意义的分解[23]。例如, Halko等人[24]提出了代表性随机近似矩阵分解(RAMD), 它揭示了一个矩阵可以通过它在随机投影的列空间上的投影来有效地近似, 并且可以被重新视为奇异值分解(SVD)/主成分分析(PCA)的快速近似。Candès等人[12]提出了RPCA, 它可以对低等级数据和稀疏噪声进行盲目分解。

在本文中, 我们采用Zhou和Tao提出的GoDec算法[25]来解决低秩背景成分和稀疏成分的问题。GoDec是一种快速的近似算法, 它用RAMD中的双边随机投影(BRPs)[26]取代了耗时的SVD/PCA。此外, GoDec算法可以探索低秩和稀疏结构, 并可以同时考虑加性噪声, 而在RPCA分解中, 加性噪声是与稀疏结构一起考虑的。基于BRP的GoDec问题可以通过在等级和稀疏约束下最小化分解误差来解决, 具体如下。

$$\min_{\mathbf{B}, \mathbf{S}} \|\mathbf{X} - \mathbf{B} - \mathbf{S}\|_F^2 \quad \text{s.t. rank}(\mathbf{B}) \leq r, \text{card}(\mathbf{S}) \leq kN \quad (4)$$

其中 r 和 k 分别代表 \mathbf{B} 的等级和 \mathbf{S} 的cardinality的上界。 \mathbf{S} 的cardinality k 反映了图像场景中的稀疏能量, 它通常被定义为 \mathbf{S} 的 ℓ_0 -norm。

表示为几个基向量的线性组合,而基向量的数量被视为背景成分矩阵的等级。这些基向量通常由背景成员、背景协方差特征向量或其他特征来描述。稀疏成分可能包含一些背景能量;因此,在确定低等级成分的等级值时,并非所有的背景材料都被考虑在内。因此, r 的值可以根据主要的背景成员或背景类别的数量来设定。详细的参数分析将在下面的实验部分进一步研究。

4) 中的优化问题可以转化为交替解决以下两个子问题,直到

收敛。

$$\mathbf{B}_{t+1} = \underset{\mathbf{B}}{\operatorname{argmin}} \|\mathbf{X} - \mathbf{B} - \mathbf{S}\|_F^2 \quad (5)$$

$$\mathbf{S}_t = \underset{\mathbf{S}}{\operatorname{argmin}} \|\mathbf{X} - \mathbf{B}_{t-1} - \mathbf{S}\|_F^2 \quad (6)$$

基于BRP的低秩近似理论被用来解决(5)中的子问题。假设

$$\mathbf{y}_1 = \mathbf{A}_1 \mathbf{x}, \mathbf{y}_2 = \mathbf{A}_2 \mathbf{x} \quad (7)$$

其中 $\mathbf{A}_1 \in \mathbb{R}^{B \times r}$ 和 $\mathbf{A}_2 \in \mathbb{R}^{N \times r}$ 是随机矩阵。对于

简单地说, \mathbf{A}_1 可以用MATLAB的randn函数得到,它可以生成一个遵循标准正态分布的随机矩阵, \mathbf{A}_2 可以通过 $\mathbf{A}_2 = \mathbf{Y}_1 \mathbf{X} \mathbf{A}_1$ 得到。

基于BRP的 $\mathbf{X} \in \mathbb{R}^{N \times B}$ 的等级- r 近似是

$$\mathbf{b} = \mathbf{y} (\mathbf{a}^T \mathbf{y}_2)^{-1} \mathbf{y}_1^T \quad (8)$$

至于(6)中的子问题, \mathbf{S}_t 是通过 $\mathbf{X} - \mathbf{B}$ 的入口硬阈值更新的 $t-1$,即。

$$\mathbf{S}_t = P_{\Omega}(\mathbf{X} - \mathbf{B}_{t-1}), \quad \Omega: (\mathbf{X} - \mathbf{B}_{t-1})_{i,j \in \Omega} = 0$$

$$\text{和} \geq (\mathbf{X} - \mathbf{B}_{t-1})_{i,j \in \bar{\Omega}}, \quad |\Omega| \leq kN \quad (9)$$

其中, $P_{\Omega}(\cdot)$ 是一个矩阵对一个条目集 Ω 的投影。而 Ω 则是" $\mathbf{X} - \mathbf{B}_{t-1}$ "的前 kN 个最大项的非零子集。

GoDec的算法可以概括为:算法1。

C. 基于Mahalanobis距离的异常情况检测

在恢复了低秩背景矩阵和稀疏矩阵后,低秩背景矩阵捕获了全局背景信息,稀疏矩阵包含了异常信息,背景和异常被分离。因此,背景的统计特征可以从背景矩阵中得到。然后,我们可以使用统计特征来建立一个基于Mahalanobis距离的异常情况检测器。该检测器被认为可以抑制异常污染问题。该检测器可以表示如下。

$$D_{(\text{LSMAD})}(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu}_b)^T \boldsymbol{\Gamma}_b^{-1} (\mathbf{x} - \boldsymbol{\mu}_b) \quad (10)$$

其中 $\boldsymbol{\mu}_b$ 和 $\boldsymbol{\Gamma}_b$ 分别是输入背景数据的平均值和协方差矩阵,可以从恢复的背景分量 $\mathbf{B} = [\mathbf{B}_1, \dots, \mathbf{B}_N]$ 中估计出来,具体如下。

$$\boldsymbol{\mu}_b = \frac{1}{N} (\mathbf{B}_1 + \dots + \mathbf{B}_N) \quad (11)$$

$$\boldsymbol{\Gamma}_b = \frac{1}{N} (\mathbf{B} - \boldsymbol{\mu})^T (\mathbf{B} - \boldsymbol{\mu}) \quad (12)$$

背景协方差matrix的eigendecomposition $\boldsymbol{\Gamma}_b$ 为

$$\boldsymbol{\Gamma}_b = \mathbf{V} \boldsymbol{\Lambda} \mathbf{V}^T \quad (13)$$

其中 $\mathbf{V} = [\mathbf{V}_1, \mathbf{V}_2, \dots, \mathbf{V}_B]$ 是特征向量矩阵, $\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_B)$ 是特征值矩阵,而 $\lambda_1 \geq \lambda_2 \geq \dots$

反协方差矩阵可以通过以下方式给出: $\lambda_i^{-1} \geq \lambda_B$ 。

$$\boldsymbol{\Gamma}_b^{-1} = \mathbf{V} \boldsymbol{\Lambda}^{-1} \mathbf{V}^T = \sum_{i=1}^B \lambda_i^{-1} \mathbf{V}_i \mathbf{V}_i^T \quad (14)$$

算法1: Godec算法

输入 : a) $\mathbf{X} \in \mathbb{R}^{N \times B}$, 数据矩阵
 a) r , 背景矩阵的最大等级
 b) k , 稀疏矩阵的cardinality
 c) ε , 误差容忍
 d) $Iter$, 最大迭代数
输出. \mathbf{B} , 低等级矩阵的近似值
 \mathbf{S} , 稀疏矩阵的近似值

步骤(1)。初始化。 $\mathbf{B}_0 = \mathbf{X}, \mathbf{S}_0 := 0, t := 0$,
 $\mathbf{A}_1 = \text{randn}(B, r)$

步骤(2)。重复 $Iter$ 次数

- $t := t + 1$
 - $\mathbf{Y}_1 = (\mathbf{X} - \mathbf{S}_{t-1}) \mathbf{A}_1, \quad \mathbf{A}_2 = \mathbf{Y}_1, \quad \mathbf{Y}_2 = (\mathbf{X} - \mathbf{S}_{t-1}) \mathbf{A}_2$
 - 如果 $\text{rank}(\mathbf{A}^T \mathbf{Y}_1) < r$, 那么 $r := \text{rank}(\mathbf{A}^T \mathbf{Y}_1)$; 转到步骤b); 结束。
 - $\mathbf{B}_t = \mathbf{Y}_1 (\mathbf{A}_1^T \mathbf{Y}_1)^{-1} \mathbf{Y}_1^T$
 - $\mathbf{S}_t = P_{\Omega}(\mathbf{X} - \mathbf{B}_{t-1})$
- 直到 $\|\mathbf{X} - \mathbf{B}_t - \mathbf{S}_t\|_F^2 / \|\mathbf{X}\|_F^2 \leq \varepsilon$

由于训练样本的缺陷,背景协方差矩阵的逆值通常是有等级缺陷的,特别是在局部方法中,当有一个某些特征值 λ_i 太小,使 λ_i^{-1} 明显增加¹。由于背景的低秩属性

分量,背景成分可以表示为几个基向量的线性组合,基向量的数量等于背景成分矩阵的等级。这些基向量通常由背景协方差矩阵的特征向量来描述。因此,低等级的背景可以由背景协方差矩阵的几个特征向量来表示,而所选的特征向量的值取决于等级值。然后可以估计出反背景协方差矩阵

通过前 r 个最大的特征值和它们相应的特征向量,如下所示。

$$\mathbf{\Gamma} = \sum_{i=1}^r \mathbf{b}^{-1} \lambda_i^{-1} \mathbf{u}_i \mathbf{u}_i^T \mathbf{V} \mathbf{V}^T. \quad (15)$$

LSMAD是一个基于Mahalanobis距离的异常检测器,它充分地利用了背景成分及其先验的低等级知识。过去十年的研究已经证明了Mahalanobis距离从复杂背景中检测异常的能力[27]-

[29]。这些基于Mahalanobis距离的方法的关键假设是,异常点和背景的统计特征可以用平均值和协方差矩阵来描述。因此,这些方法的主要区别在于计算背景的平均值和协方差矩阵的方式不同。对于原始的RX和SSRX,它们在没有任何异常假设的情况下进行背景估计。同时,BACON使用一个假设为无异常的初始子集,这对最终的背景像素集有相当大的影响。拟议的LSMAD并没有找到一个最佳的初始子集,而是定义了稀疏矩阵中非零像素的数量。然后进行足够次数的LRaSMD过程,以确保在低秩和稀疏约束下分解误差最小,这可以从噪声中恢复信号,并进一步将背景与稀疏材料(包括异常情况)分开。此外,尽管稀疏像素可能不是感兴趣的异常点,它们可能包括其他稀疏的背景材料,但这对大多数背景统计变量不会有明显的影响。除了缓解异常点污染问题外,LSMAD方法还进一步探索了背景成分的低秩先验知识,用于反协方差矩阵的估计,这可以避免基于Mahalanobis距离的局部检测器中的奇异和不稳定的反协方差矩阵问题。

LSMAD为LRaSMD提供了一个新的视角,用于hyperspectral异常检测,并集中于可靠的背景成分。在以前的研究中[15],

[16], (3)中的三个分量中的稀疏分量一直是异常检测的首选,稀疏分量的规范或欧氏距离一直被用来开发异常检测器。这些基于稀疏分量的检测器的关键假设是,稀疏分量传达了感兴趣的异常信息,每个像素的检测统计只依赖于相应的稀疏分量向量,而忽略了背景分量和像素的原始图像信息。然而,基于背景分量的LSMAD比基于稀疏分量的检测器更加稳健。详细来说,在LRaSMD恢复过程中,通常不能有效地提取异常能量。如图1所示,异常能量不仅被稀疏矩阵 \mathbf{S} 所反映,也被背景矩阵所反映,甚至被噪声矩阵所反映,这将影响基于稀疏成分的探测器的检测概率。此外,如图2所示,稀疏分量通常同时包含异常点和稀疏背景材料,这最终可能会增加




图1.在PaviaC数据集中,当异常能量在 $k=0$.时未被充分提取时的恢复性能。




图2.在PaviaC数据集中,当背景分量和稀疏分量在 $k=0$.时不能很好地分离时的恢复性能。

的错误警报。然而,即使在LRaSMD恢复过程中仍然存在背景分量的异常污染,异常污染对LSMAD的影响也可以最终得到抑制。其原因是含有大量异常信息的低特征值的特征向量在反协方差矩阵估计中被拒绝。

III. 高光谱数据实验

A. 高光谱数据集和实验平台

本研究使用了四个高光谱数据集来评估第二节中介绍的拟议探测器的有效性。我们使用了四个具有不同特征的数据集,包括数据收集仪器、目标大小和目标的空间分布。实验平台是一台具有Intel(R) Core(TM) i3 2.20-GHz中央处理器、4-GB内存和64位Windows的个人电脑。所有7.的算法都在MATLAB 2014a中实现。

第一个数据集是由反射光学系统成像光谱仪传感器[16]收集的。它是意大利北部帕维亚市中心的一个场景,如图3(a)所示。该图像场景覆盖了108 120个像素的区域,有102个光谱带,波长范围从430纳米到860,空间分辨率为1.3米。主要的背景材料是桥和水。如图3(b)所示,桥上有一些车辆,桥墩附近有裸露的土壤,总共有43个像素,占图像场景的0.33%。如图3(c)所示,这些像素的光谱特征与主背景不同,因此,这些像素被选为要检测的异常点。

第二组数据是由美国加州圣地亚哥的机载可见光/红外成像光谱仪(AVIRIS)收集的。空间分辨率为3.5每像素米[30], [31]。该数据集

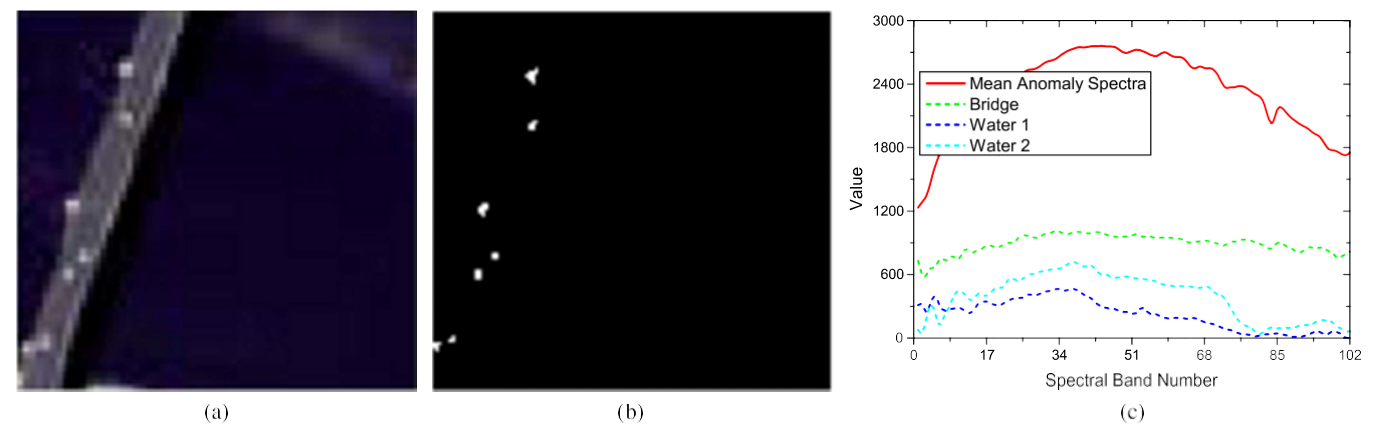


图 (3.a) PaviaC图像场景。(b) 异常点位置。(c) 异常点和背景类的光谱特征。

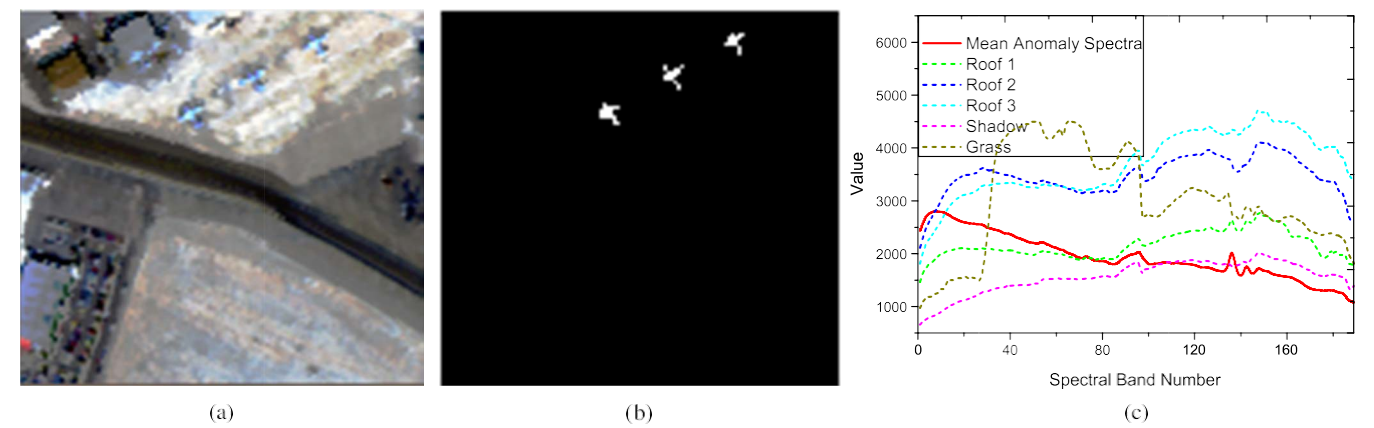


图 (4.a) AVIRIS图像场景。(b) 异常点位置。(c) 异常点和背景类的光谱特征。

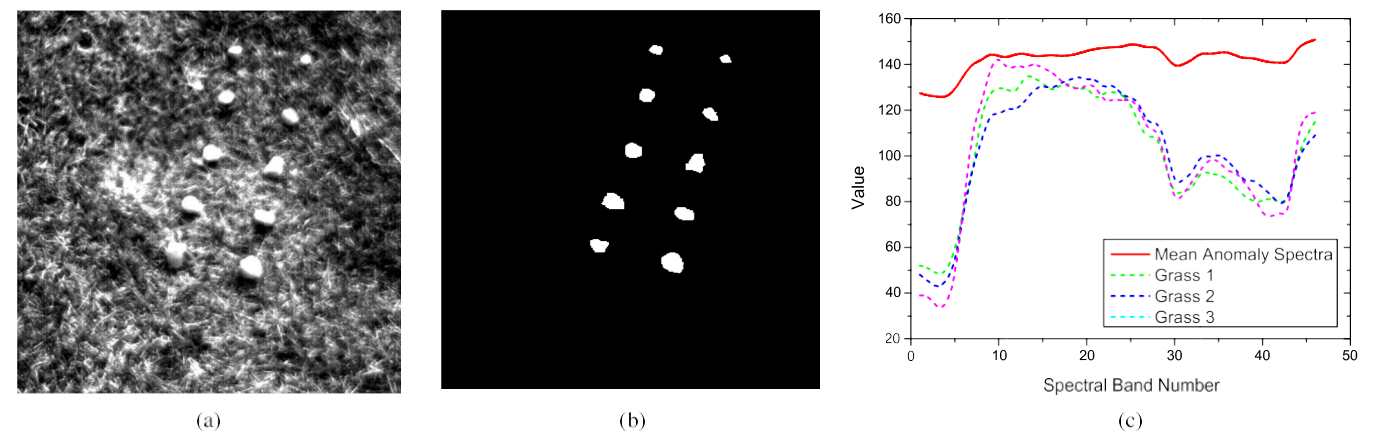


图 (5.a) Cui图像场景。(b) 异常点位置。(c) 异常点和背景类的光谱特征。

图像有224个光谱通道，波长范围从370到2510纳米。在去除对应于水吸收区域、低信噪比和不良波段（1-6、33-35、107-97,113、153-166和221-224）的波段后，189实验中保留了数据中的可用波段。如图4(a)所示，从这个高光谱数据集中选择了一个大小为120像素120的区域来测试检测性能。该数据集是一个城市场景，其中的主要背景材料是屋顶、阴影和草地。这里有

如图4(b)所示，图像中有三个平面，它们由58个像素组成，占图像的0.33%。如图4(c)所示，这些平面的光谱特征与主要背景不同，因此，这些像素被选为要检测的异常点。

第三组数据是由Nuance Cri超光谱传感器[32]获取的。这种传感器可以获得光谱分辨率为纳米10的图像。如图5(a)所示，图像场景覆盖了×个400像素400的区域，其光谱46带为

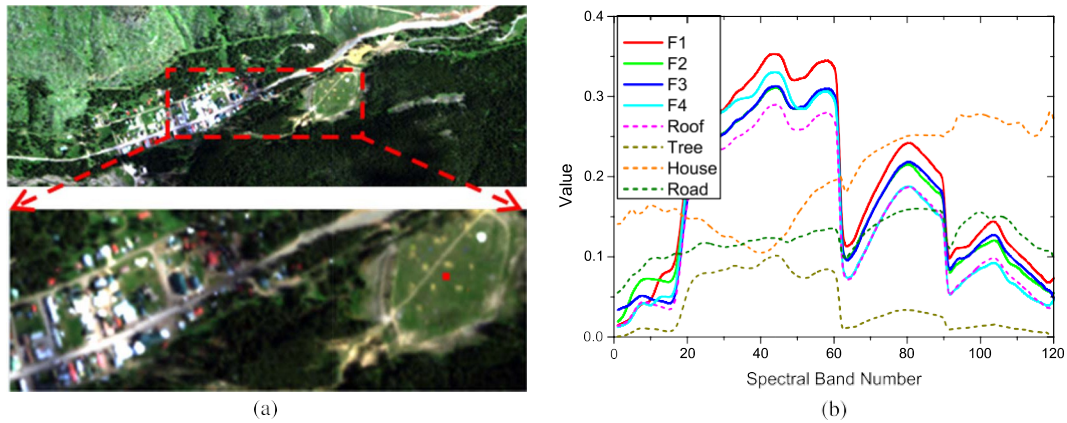


图 (6.a) HyMap图像场景和目标F1位置 (子图像右侧的红色像素)。(b) 背景类和四个织物目标的光谱特征。

在波长为650至1100纳米的范围内。如图5(b)所示, 在草地场景中有10块岩石, 它们由2216个像素组成, 占图像的1.385%。如图5(c)所示, 这些岩石的光谱特征与主要背景截然不同, 因此, 这些像素被选为要检测的异常点。

第四组数据是HyMap图像, 它是7月在美国MT的库克城小镇所在地拍摄的[4,332006], [34]。该图像场景覆盖了200800像素的区域, 有126个光谱带, 波长范围从450到2500纳米。在去除不良波段后, 保留了120个波段的数据。图像中共有七种类型的目标, 包括四个织物板目标和三个车辆目标。在这个实验中, 我们裁剪了一个大小为100300的住宅区子图像, 如图6(a)所描述的。该子图像的主要背景类型是屋顶、道路、草地和树木; 背景和织物目标的光谱特征如图6(b)所示。由于四个织物目标和背景草类的光谱相似度很高, 该数据集对异常检测具有挑战性。四个目标中的目标F1与主要背景相比, 具有最不同的光谱特征, 因此我们将其视为待检测的异常点。

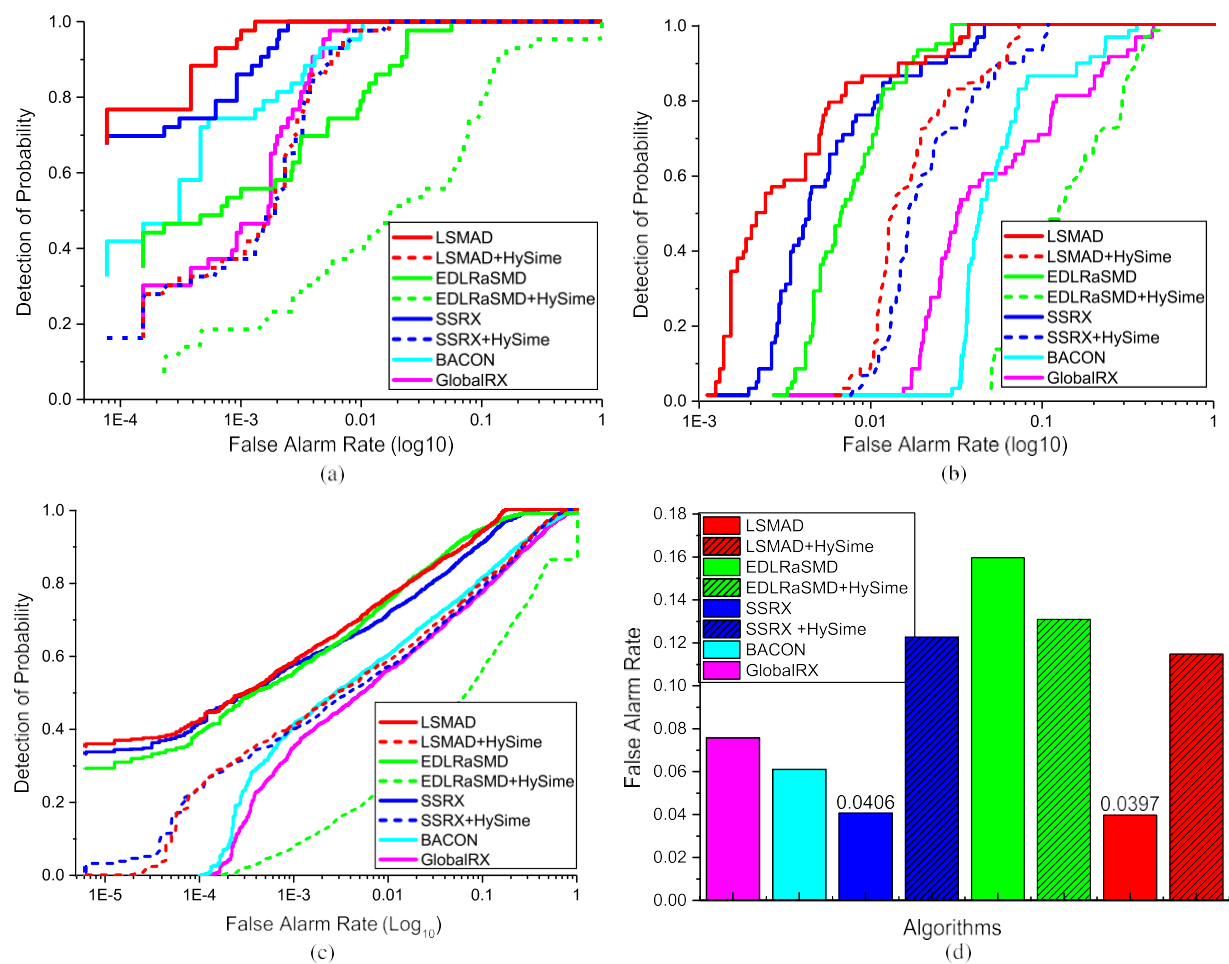
B. 探测性能和参数分析

对拟议的LSMAD的检测性能和时间消耗进行了评估, 并与其他四个最先进的检测器进行了比较。Global RX (GRX)、BACON、SSRX和EDLRaSMD。LSMAD的等级值可以通过经验方法设定。从现有的出版物[16], [35]-[38]的结果中, 我们可以发现, 等级值通常是非常小的。例如, [16]测试了2-10的等级值, [36]测试了1-40的等级值, 发现适当的等级值很小 (例如, $r \leq 5$), 而[37]将该值定为此外1., 根据对[35], LRaSMD模型中的等级与主要背景图像类别的数量高度相关。因此, 我们可以按照大多数相关出版物的方式, 在检测程序之前凭经验确定等级, 并根据经验为我们的工作选择一个粗略的等级值。一个

经验等级值为或1, 2用于LSMAD。对于有一个主导类别的数据集, 如PaviaC和HyMap, 1被设定为等级值。对于有两个主导类别的数据集, 如Cri和AVIRIS, 2被设定为等级值。另一方面, 许多存在的算法也可以在本实验中通过各自的自动方法提供一个候选等级值, 如著名的高光谱信号子空间识别最小误差 (HySime) 算法[39]。因此, 我们用HySime算法或根据经验确定的方法来比较检测性能。拒绝SSRX的成分数量可以根据特征值调查在理论上进行选择。我们知道, 在自然背景的超光谱数据集中, 协方差矩阵的较大特征值通常比最小的特征值大几个数量级[4]。较大的特征值的数量通常很小, 并且接近于图像中背景材料的数量。因此, 为了方便起见, 我们通常根据背景类的数量来选择SSRX要拒绝的成分数量, 这也可以根据经验确定或通过HySime算法确定。稀疏矩阵的cardinality k 是根据图像场景中异常点的比例 (RAI) 来设置的。如图7(a)-

(c)所示, 所有检测器的实验结果都是通过前三组数据的接收操作特性(ROC)曲线提供的。由于HyMap数据集的异常点数量较少, 我们通过检测概率达到100%时的误报率 (FAR) 提供实验结果, 如图7(d)所示。

对于PaviaC数据集, 如图7(a)所示, LSMAD的结果显示出比其他去检测算法更好的性能。LSMAD也产生了比EDLRaSMD更好的检测性能。当达到100%的检测概率时, LSMAD和EDLRaSMD的FARs分别0.1, 约为和0.001。BACON和SSRX的检测性能比GRX的检测性能有明显改善。对于AVIRIS数据集, 如图7(b)所示, LSMAD的ROC曲线总是高于SSRX、BACON和GRX。此外, 当FAR小于EDLRaSMD时, LSMAD的ROC曲线高于EDLRaSMD。对于0.016.Cri数据集, 如图7(c)所示, LSMAD、SSRX和EDLRaSMD的ROC曲线没有分开。



图：四个数据集的检测7.性能。

表一
四个数据集的时间消耗

Time (s)	GRX	SSRX	BACON	EDLRaSMD	LSMAD
PaviaC	0.14	0.45	24.61	11.40	10.77
AVIRIS	0.33	1.86	42.00	25.20	27.24
Cri	1.50	2.53	885.46	61.73	64.18
HyMap	0.43	2.37	316.22	31.13	29.68

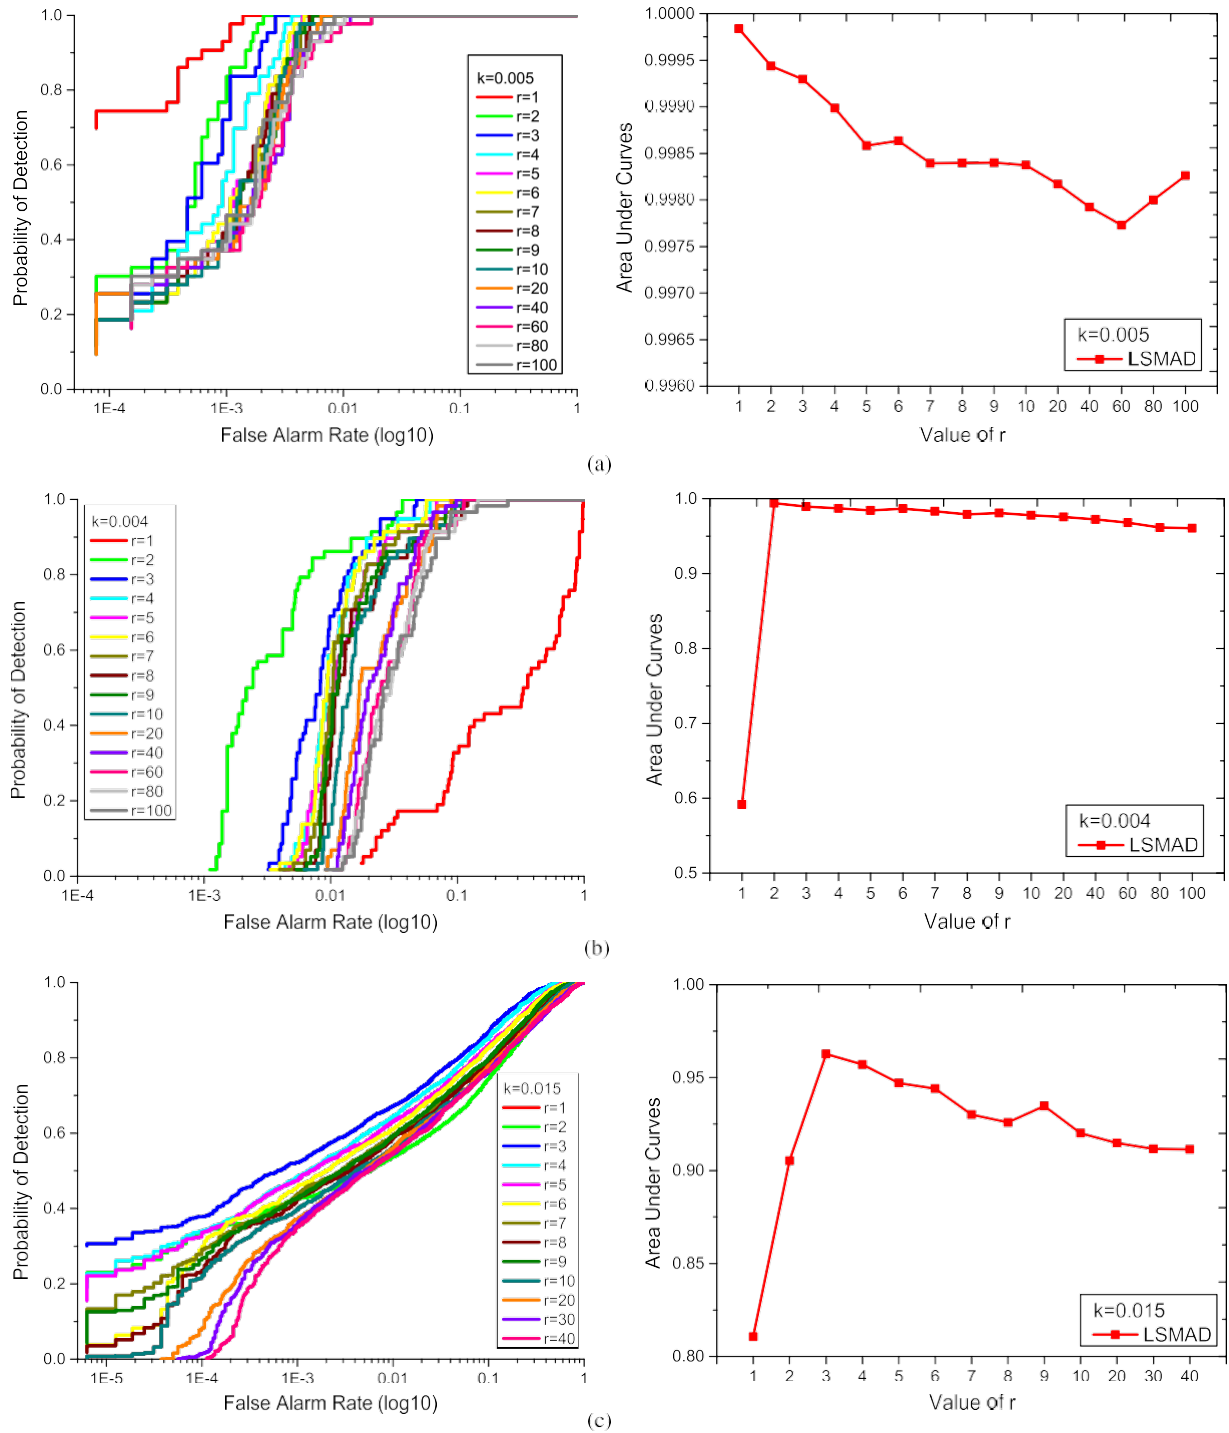
到目前为止，它们在PaviaC和AVIRIS数据集中都是如此。尽管如此，LSMAD的ROC曲线几乎总是高于SSRX、BACON和GRX的曲线。此外，当FAR小于0.0147时，LSMAD的ROC曲线也高于EDLRaSMD。对于HyMap数据集，结果表明，拟议的LSMAD提供了比其他算法更好的检测性能。此外，如表一所示，拟议的LSMAD的时间成本是可以接受的，与EDLRaSMD大致相同，低于BACON的成本。

总的来说，使用HySime算法，LSMAD、EDLRaSMD和SSRX的性能分别比根据经验确定的等级值下降。在HySime算法下，LSMAD对PaviaC和HyMap数据集的性能要弱于GlobalRX和BACON；在HySime算法下，LSMAD对AVIRIS数据集的性能仍然优于其他竞争算法，LSMAD对Cri

在GRX、BACON和SSRX算法中，数据集或多或少非常相似。尽管现有的算法，如HySime算法，可以在没有其他补充信息的情况下提供一个等级候选，但它们不一定能提供满意的检测性能。

总的来说，根据经验确定的等级值，LSMAD在所有四个数据集上的表现普遍最好。在检测方面的这种优异表现的主要原因如下。1) 由于基于Mahalanobis距离的discriminative方法的基本属性，所提出的算法学习了一个超平面，可以通过Mahalanobis距离将异常点和背景分开；2) 引入的LRaSMD有助于获得有效的背景估计，并进一步掌握逆背景协方差矩阵估计的低秩属性；以及3) 较小的等级值可能适用于我们的数据集，因为异常样本与背景样本呈现出明显的分离，而且很少有基向量可以合成子空间，用于分离异常和背景。

为了进一步分析等级参数 r 对LSMAD最终检测性能的影响，基于PaviaC、AVIRIS和Cri数据集，研究了LSMAD相对于背景矩阵的等级参数 r 的性能。在不丧失一般性的情况下，我们对这三个数据集的 r 进行了大范围的测试。稀疏矩阵的cardinality k

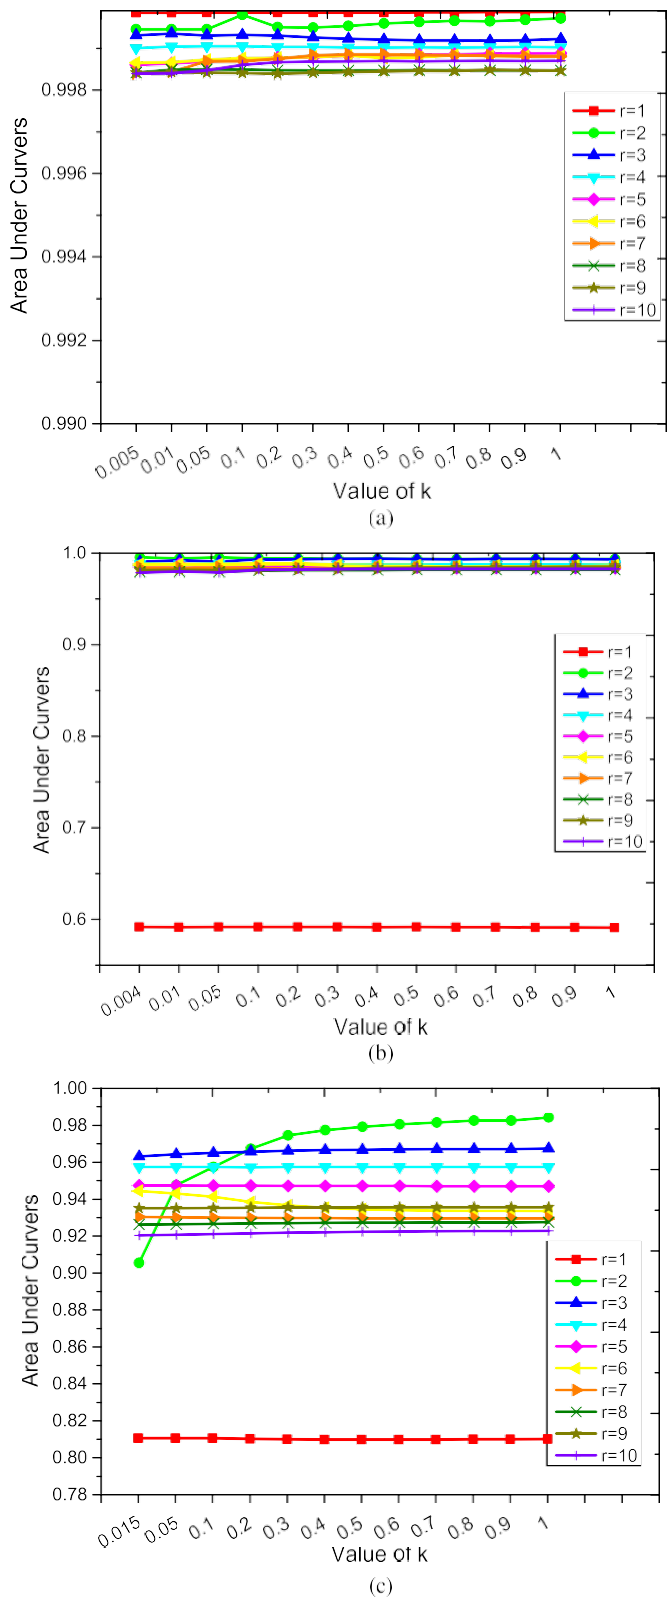


图：LSMAD在三个数据集的背景等级方面的ROC和AUC性能。(a) PaviaC。(b) AVIRIS。(c) Cri。

是与RAI有关的。由于在检测到所有的异常情况时总会有一些误报，因此我们将RAI值放宽到0.005、0.004和0.015，作为PaviaC、AVIRIS和Cri数据集的 k 值。实验结果通过ROC曲线和曲线下面积（AUC）提供，如图所示。

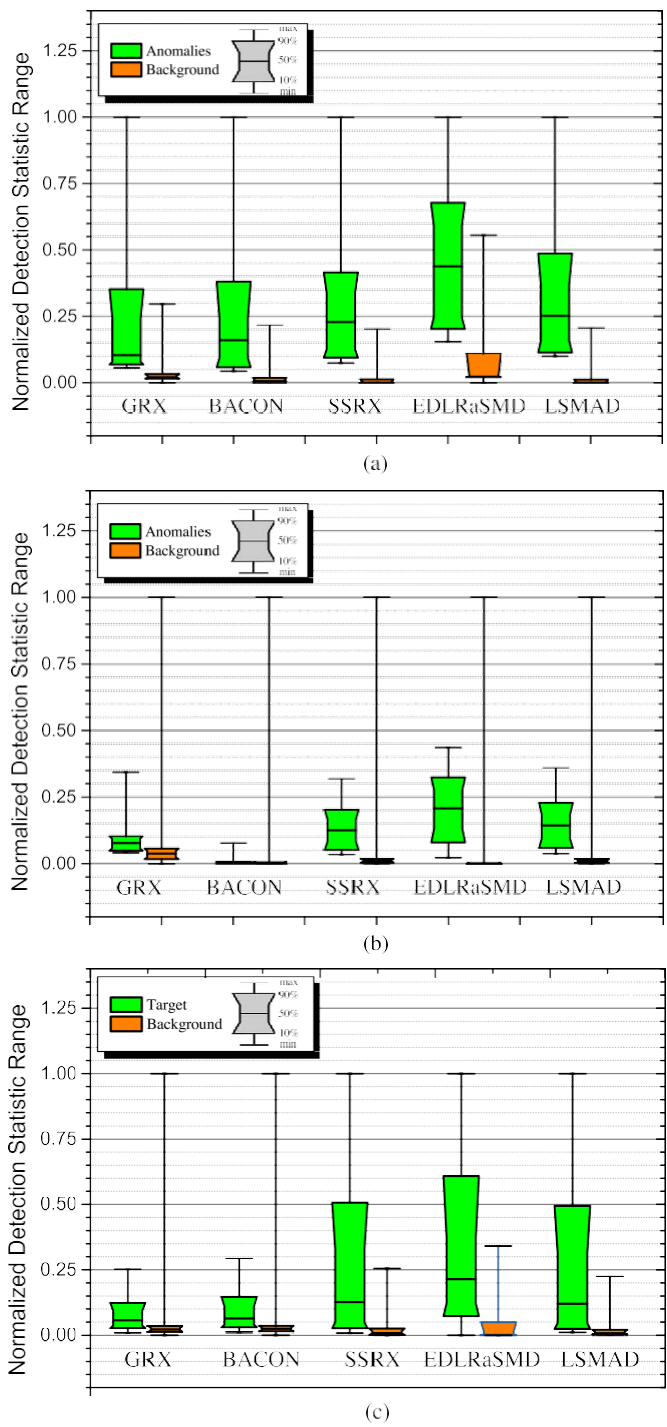
图中的结果普遍显示，所提出的LSMAD在很低的等级值下呈现出最好的性能，然后，检测性能逐渐缓慢下降。对于图8(a)中的PaviaC数据集，LSMAD表现得最好

当等级 r 等于1时，检测性能随着 r 的增加而逐渐缓慢下降。对于图8(b)中的AVIRIS数据集，LSMAD的检测性能随着等级 r 增加到2而提高，此后，检测性能随着 r 的增加逐渐缓慢下降。对于图8(c)中的Cri数据集，LSMAD的检测性能随着等级 r 增加到3而提高，之后，检测性能随着 r 增加而逐渐缓慢下降。结论是，在LSMAD中，根据经验确定的很低的等级值对各种HSI是有效的。大多数



图：LSMAD的性能9.与cardinality参数的关系。
(a) PaviaC.(b) AVIRIS。 (c) Cri.


基于低秩稀疏分解的方法也得出同样的结论[16], [35]-[38]。LRA-SMD模型中的稀疏成分可能包含一些背景能量；因此，并非所有的背景材料都被考虑在内



图：三个数据集的五个检测器的可分离性10.图。
(a) PaviaC.(b) AVIRIS。 (c) Cri.

在确定低等级分量的等级值时。这提供了一个可能的解释，即一个非常低的等级值是首选。此外，根据[35]的分析，背景成分矩阵的等级与类别的数量高度相关；因此，另一种可能的经验性估计等级值的方法是通过恒生指数的主要背景类别的数量来确定它。

此外，还分析了LSMAD在稀疏矩阵的cardinality参数k方面的性能。稀疏矩阵的cardinality k被设定在宽松的



图：PaviaC数据集的检测测试统计结果的二维图。(a) GRX.(b) BACON.(c) SSRX.(d) EDLRaSMD。(e) LSMAD。

三个数据集的RAI值和1。为了方便和准确，我们设置了一个小的步长，从下限值到0.1然后设置一个较大的步长，从0.1到1。为方便起见， r 的1.值被设置在1到10之间。实验结果通过AUCs提供。

从图9中LSMAD的结果，我们可以看到，随着 k 值的增加，每个等级值的AUC值几乎保持不变。基于上述结果，我们可以做如下总结。LSMAD可以在广泛的 k 值范围内实现良好的检测性能。其原因可能如下。Cardinality参数控制着稀疏矩阵中的稀疏能量。因此，从一个小值开始增加 k 的值会导致越来越多的异常点的独特特征被包括在稀疏矩阵中。然而，随着 k 的持续增加，背景像素的一些光谱特征也将被包括在稀疏矩阵中，这降低了异常点和背景之间的可分离性。然而，少数被纳入的异常像素对LSMAD的背景统计估计的影响很小。

为了进一步研究LSMAD区分异常点和背景的能力，评估了异常点和背景之间的可分离性，并通过可分离性地图与其他检测器进行比较，如图10所示。在对每个像素的检测值进行统计计算后，画出方框，将像素的主要部分包围起来，排除最大的10%和最小的10%。每个检测器都有异常和背景栏。每一列的顶部和底部的线条是极端值，被归一化为0-1。

绿色方框说明了异常像素值的分布，方框中间的线是像素的平均值。以类似的方式，橙色方框包围了背景像素的中间80%的主要像素。盒子的位置反映了像素分布的倾向性和紧凑性。换句话说，这个位置反映了异常点和背景的可分离性。

对于PaviaC数据集，如图10(a)所示，与GRX相比，BACON和SSRX逐渐地、连续地增加了异常盒和背景盒之间的差距。SSRX、EDLRaSMD和LSMAD的两个盒子之间的差距非常明显，而LSMAD的差距略大。与EDLRaSMD相比，LSMAD可以有效地抑制背景信息。

在这个数据集中，特别是中间80%的主背景像素。对于AVIRIS数据集，如图10(b)所示，检测变得复杂，因为所有探测器的异常和背景框之间的间隙都比其他数据集小得多。


对于GRX和BACON来说，异常框与背景框是重叠的。LSMAD的异常和背景框之间的差距比SSRX的略大。对于Cri数据集，如图10(c)所示，检测变得很复杂，因为几乎所有的检测器的异常框和背景框之间都几乎没有空隙。然而，LSMAD仍然可以有效地抑制这个数据集的背景信息。基于上述结果，我们可以看到LSMAD总体上比GRX和BACON表现更好。

因为在PaviaC和AVIRIS数据集上，异常和背景框之间的空隙明显大于GRX和BACON，而在Cri数据集上抑制背景信息的表现略好。LSMAD的表现也比SSRX好，因为在PaviaC和AVIRIS数据集上，异常点和背景框之间的差距比SSRX略大，而在Cri数据集上，抑制背景信息的表现略好。此外，LSMAD总体上优于EDLRaSMD，因为在PaviaC数据集上，异常和背景框之间的差距比EDLRaSMD大，而且在抑制背景信息方面的表现也比EDLRaSMD好。


EDLRaSMD与PaviaC和Cri数据集。

最后，图11-

13显示了所有比较算法在三个数据集下的检测测试统计结果的二维图。对于PaviaC数据集，如图11所示，我们可以看到，与EDLRaSMD相比，提议的LSMAD提供了一个可区分的统计图，它对背景桥梁像素显示出高的统计值。然而，LSMAD和其他四个检测器之间的差异是微妙的，它们不容易被区分。对于AVIRIS数据集，如图12所示，LSMAD与所有其他探测器相比，呈现出明显的可区分的统计图。SSRX和EDLRaSMD也显示了异常像素的高统计值，但与LSMAD相比，一些树或草的像素，特别是在图像的左下角，也输出了高值，这将导致错误警报。对于Cri数据集，如图13所示，LSMAD与GRX、BACON相比，呈现出明显的可区分的统计图。



图：AVIRIS数据集的探测测试统计结果的二维12.图。(a) GRX。(b) BACON。(c) SSRX。(d) EDLRaSMD。(e) LSMAD。



图：Cri数据集的检测测试统计结果的二维13.图。(a) GRX。(b) BACON。(c) SSRX。(d) EDLRaSMD。(e) LSMAD。

和EDLRaSMD。然而，用肉眼观察，LSMAD和SSRX之间的差异是微妙的。可以看出，EDLRaSMD对异常像素输出高的统计值，但图像中的许多其他像素也输出高值，这将导致误报。

IV. 结论

在本文中，LSMAD作为一种新的观点被提出，采用LRaSMD进行高光谱异常检测。基于LRaSMD技术和高光谱异常检测问题的一致性，该算法利用LRaSMD获得低秩背景和稀疏分量。然后采用GoDec算法来解决背景和稀疏分量的优化问题。为了避免不稳定的稀疏分量，通过采用估计的背景分量和为逆背景协方差矩阵估计强加的低秩背景属性，引入了Mahalanobis距离。这样，LSMAD能够同时缓解异常污染、反协方差矩阵问题和LRaSMD参数不稳定的问题。

用四个数据集进行的高光谱检测实验证实了所提出的LSMAD算法的卓越性能。与其他先进的检测器相比，LSMAD呈现出卓越的检测性能和可分离能力。总的来说，在HySime算法下，LSMAD、EDLRaSMD和SSRX的性能都比根据经验确定的等级值要低。尽管现有的算法，如HySime算法，可以在没有其他补充信息的情况下提供一个等级候选，但它们不一定能提供满意的检测性能。然而，这种经验性的

在现实应用中，参数选择方法是对所提方法的操作适用性的一个限制，这将是未来工作的重点。

鸣谢

作者要感谢处理编辑和匿名审稿人的仔细阅读和有益评论。

参考文献

- [1] G. Manolakis, "高光谱图像利用的信号处理", *IEEE信号过程. Mag.* 第19卷, 第1期, 第12-16页, 1月。2002.
- [2] D.Landgrebe, "高光谱图像数据分析", *IEEE Signal Process.Mag.*, 第19卷, 第1期, 第17-28页, 1月。2002.
- [3] M.Borengasser, W. S. Hungate, and R. Watkins, *Hyperspectral Remote Sensing-Principles and Applications*. Boca Raton, FL, USA: CRC Press, 2008.
- [4] R.Zhao, B. Du, and L. Zhang, "A robust nonlinear hyperspectral anomaly detection approach," *IEEE J. Sel.Earth Observ.遥感*, 第7卷, 第4期, 4, pp.1227-1234, Apr.2014.
- [5] B.Du and L. Zhang, "Random-selection-based anomaly detector for hyperspectral imagery," *IEEE Trans.Geosci.遥感*, 第49卷, 第5, pp.1578-1589, May 2011.
- [6] C.-I.Chang, "Target signature-constrained mixed pixel classification for hyperspectral imagery," *IEEE Trans.Geosci.*1065-1081, May40,5, 2002.
- [7] I.C. Chein and C. Shao-Shan, "Anomaly detection and classification for hyperspectral imagery," *IEEE Trans.Geosci.遥感*, 第40卷, 第1314-1325页6., 六月。2002.
- [8] D.Manolakis, D. Marden, and G. A. Shaw, "Hyperspectral image processing for automatic target detection applications," *J. Lincoln Lab.*, vol. no14,,1, pp.79-116, 2003.
- [9] J.E. Fowler和Q. Du, "Anomaly detection and reconstruction from random projections," *IEEE Trans.Image Process.*第21,184-195页1., 1月。2012.
- [10] S.Matteoli, M. Diani, and G. Corsini, "A tutorial overview of anomaly detection in hyperspectral images," *IEEE Aerosp.Electron.Syst.Mag.*, vol. no25,,7, pp. 5-28, Jul. 2010.

- [11] D.W. J. Stein 等人, "高光谱图像的异常检测", *IEEE Signal Process. Mag.*, 第19,58-69页1,, 1月。 2002.
- [12] I.S. Reed和X. Yu, "具有未知光谱分布的光学图案的自适应多波段CFAR检测", *IEEE Trans. Acoust. Speech Signal Process.* 第38,1760-1770页10,, 10月。 1990.
- [13] A.P. Schaum, "高光谱目标的联合子空间检测", in *Proc. IEEE Aerosp. Conf.*, 2004, pp.1818-1824.
- [14] S. Matteoli, M. Diani, and G. Corsini, "Impact of signal contamination on the adaptive detection performance of local hyperspectral anomaly detection," *IEEE Trans. Geosci. Remote Sens. Lett.*, 第52卷, 第4期, 4, pp.1948-1968, Apr. 2014.
- [15] M.D. Farrell和R. M. Mersereau, "On the impact of covariance contamination for adaptive detection in hyperspectral imaging," *IEEE Signal Process. Lett.* 1, no. 9, pp. 649-652, Sep. 2005.
- [16] N. Billor, S. Hadia, and P. F. Velleman, "BACON: Blocked adaptive computationally efficient outlier nominators," *Comput. Statist. Data Anal.*, vol. 34, no.3, pp. 279-298, Sep. 2000.
- [17] T.E. Smetek和K. W. Bauer, "Finding hyperspectral anomalies using multivariate outlier detection," in *Proc. IEEE Aerosp. Conf.*, 2007年, 第1-24页。
- [18] S. Matteoli, M. Diani, and G. Corsini, "Hyperspectral anomaly detection with Kurtosis-driven local covariance matrix corruption mitigation," *IEEE Geosci. Remote Sens. Lett.* 第8,532-536页3,, 2011年5月。
- [19] A. Banerjee, P. Burlina, and C. Diehl, "A support vector method for anomaly detection in hyperspectral imagery," *IEEE Trans. Geosci. Remote Sens. Lett.* 第44卷, 第8期, 第2282-2291页, 8月。 2006.
- [20] S. Khazai, S. Homayouni, A. Safari, and B. Mojaradi, "Anomaly detection in hyperspectral images based on an adaptive support vector method," *IEEE Geosci. Remote Sens. Lett.* pp.4,646-650, Jul8,, 2011.
- [21] E.J. Candès, X. Li, Y. Ma, and J. Wright, "鲁棒性主成分分析?" *J. ACM*, 第58卷, 第1-37页3,, 5月。 2011.
- [22] A. Sumarsono和Q. Du, "Robust principal component analysis for hyperspectral anomaly detection," in *Proc. IEEE IGARSS*, pp2014,.
- [23] L. Xiong, X. Chen, and J. Schneider, "Direct robust matrix factorization for anomaly detection," in *Proc. IEEE ICDM*, pp2011, 1-10.
- [24] X. Cui, Y. Tian, L. Weng, and Y. Yang, "Anomaly detection in hyperspectral imagery based on low-rank and sparse decomposition," in *Proc. 5th ICGIP*, vol2013, 9069, 1-73.
- [25] W. Sun, C. Liu, J. Li, Y. M. Lai, and W. Li, "Low-rank and sparse matrix decomposition-based anomaly detection for hyperspectral imagery," *J. 应用遥感*, 第8,1-18页1,, 5月 2014.
- [26] Y. Chen, N. M. Nasrabadi, and T. D. Tran, "Sparse representation for target detection in hyperspectral imagery," *IEEE J. Sel. Topics Signal Process.*, vol. 5, no.3, pp. 629-640, Jun. 2011.
- [27] M. Golbabaei和P. Vandergheynst, "通过低秩和联合稀疏矩阵恢复的高光谱图像压缩传感", 在 *Proc. IEEE ICASSP*, 第2012,2741-2744页。
- [28] K. Rong, S. Wang, X. Zhang, and B. Hou, "Low-rank and sparse matrix decomposition-based pan sharpening," in *Proc. IEEE IGARSS*, pp2012,2276-2279.
- [29] Y. Xue, X. Guo, and X. Cao, "Motion saliency detection using low-rank and sparse decomposition," in *Proc. IEEE ICASSP*, pp2012,1485-1488.
- [30] Y. Zhang, B. Du, and L. Zhang, "Regularization framework for target detection in hyperspectral imagery," *IEEE Geosci. Remote Sens. Lett.* 第11卷, 第1期, 第313-317页, 1月。 2014.
- [31] Z. Zhou, X. Li, J. Wright, E. J. Candès, and Y. Ma, "稳定的主成分追求", 在 *Proc. IEEE ISIT* 中, 第2010,1518-1522页。
- [32] T. Zhou, D. Tao, and X. Wu, "Manifold elastic net: 稀疏降维的统一框架", 《数据挖掘知识》, 第1期, *Discovery*, vol. no22, 3, pp.340-371, May 2011.
- [33] N. Halko, P. G. Martinsson, and J. A. Tropp, "Finding structure with randomness: 构建近似矩阵分解的随机算法", *SIAM Rev.*, 卷号53,, 第217-288页2,, May 2009.
- [34] T. Zhou and D. Tao, "Godec: 随机化的低秩和稀疏矩阵分解", 在 *Proc. 28th ICML*, 第33-40页2011,。
- [35] T. Zhou and D. Tao, "Bilateral random projection," in *Proc. IEEE ISIT*, 2012, pp.1286-1290.
- [36] H. Viljoen和J. H. Venter, "识别多变量不和谐观察。A computer-intensive approach," *Comput. Statist. Data Anal.* 第40卷, 第1期, 第159-172页, 7月。 2002.
- [37] L.H. Chiang, R. J. Pell, and M. B. Seasholtz, "使用稳健的离群点检测算法来探索过程数据," *J. Process Control*, vol. 13, no.5, pp. 437-449, Aug. 2003.
- [38] C. Becker和U. Gather, "The masking breakdown point of multivariate outlier identification rules," *J. Amer. Stat. Assoc.*, vol. 94, no.447, pp.947-955, Sep. 1999.

- [39] Y. Gu, C. Wang, S. Wang, and Y. Zhang, "Kernel-based regularized-angle spectral matching for target detection in hyperspectral imagery," *Pattern Recognit. Lett.* 第32卷, 第114-119页, 2011年1月。
- [40] L. Zhang, L. Zhang, D. Tao, and X. Huang, "Sparse transfer manifold embedding for hyperspectral target detection," *IEEE Trans. Geosci. 遥感*, 第52卷第2期, 第1030-1043页, 2014年2月。
- [41] L. Zhang, B. Du, and Y. Zhong, "Hybrid detectors based on selective endmembers," *IEEE Trans. Geosci. 遥感*, 第48卷, 第6期, 第2633-2646页, 6月。2010。
- [42] W. Li and Q. Du, "Collaborative representation for hyperspectral anomaly detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 53, no. 3, pp. 1463-1474, Mar. 2015.
- [43] L. Ma, M. M. Crawford, and J. Tian, "Anomaly detection for hyperspectral images based on robust local linear embedding," *J. Infrared*, vol. no. 31, no. 6, pp. 753-762, Jun. 2010.
- [44] A. Sumarsono and Q. Du, "Low-rank subspace representation for estimating the number of signal subspaces in hyperspectral imagery," *IEEE Trans. Geosci. 遥感*, 第53卷, 第11期, 第6286-6292页, 11月。2015。
- [45] X. X. Yuan and J. Yang, "Sparse and low-rank matrix decomposition via alternating direction methods," *Pacific J. Optim.*, 第9卷, 第1期, 第1-11页。2009。
- [46] H. Zhang, W. He, L. Zhang, H. Shen, and Q. Yuan, "Hyperspectral image restoration using lowrank matrix recovery," *IEEE Trans. Geosci. 遥感*, 第52卷, 第8期, 第4729-4743页, 8月。2014。
- [47] J. M. Bioucas-Dias and J. P. Nascimento, "高光谱子空间识别," *IEEE Trans. Geosci. 遥感*, 第46卷, 第8期, 第2435-2445页, 8月。2008。

张玉香 (S'13) 于2011年在武汉大学获得遥感科学与技术学士学位。她目前正在武汉大学攻读遥感科学与技术的博士学位。

她的研究兴趣包括高光谱图像处理、目标检测、稀疏表示和信号处理。



杜波 (M'10-SM'15) 分别于2005年和2010年在中国武汉的武汉大学获得工程学士学位和摄影测量与遥感的博士学位。

他目前是武汉大学计算机学院的副教授。他有超过

在IEEE TRANSACTIONS ON IMAGE PROCESSING (TIP)、IEEE JOURNAL OF SELECTED TOPICS IN EARTH OBSERVATIONS AND APPLIED REMOTE SENSING (JSTARS) 和IEEE GEOSCIENCE等期刊上发表20篇研究论文

和REMOTE SENSING LETTERS (GRSL) 等。他的主要研究兴趣包括模式识别、高光谱图像处理 and 信号处理。

杜教授担任多个科学引文索引杂志的审稿人, 包括IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING, TIP, JSTARS, and GRSL。





张良培 (M'06-

SM'08) 1982年在中国长沙的湖南师范大学获得物理学学士学位, 1988年在中国西安的中国科学院西安光学与精密机械研究所获得光学硕士学位, 1998年在中国武汉的武汉大学获得摄影测量和遥感博士学位。

他目前是测绘遥感信息工程国家重点实验室遥感部主任。

国教育部批准的

"长江学者

"讲座教授。他目前是中国国家科技部指定的中国国家重点基础研究项目 (2011-

2016) 的首席科学家, 领导中国的遥感项目。他有多篇研究450论文和五本著作。他是15项专利的持有人。他的研究兴趣包括高光谱遥感、高分辨率遥感、图像处理和人工智能。

张博士是英国工程和技术学会会员。他是IEEE地球科学和遥感学会 (GRSS) 武汉分会的创始主席。他是第四届IEEE

GRSS高光谱图像和信号处理研讨会的总主席。遥感的发展。他是国际地图-

生物圈计划中国国家委员会的执行委员 (理事会) 和中国图像与图形学学会的执行委员, 等等。他经常担任SPIE多光谱图像处理和模式识别系列会议、亚洲遥感会议和其他许多会议的联合主席。他编辑了一些会议论文集、期刊和地理信息学研讨会。他目前担任IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING的副编辑。他

他还担任《国际环境计算与智能杂志》、《国际图像与图形杂志》、《国际数字多媒体广播杂志》、《地理空间信息科学杂志》和《遥感杂志》的副编辑, 以及《应用遥感杂志》和《传感器杂志》的客座编辑。他一直是IEEE JOURNAL OF SELECTED TOPICS IN EARTH OBSERVATIONS AND APPLIED REMOTE SENSING的客座编辑。

(JSTARS)。他是2010年波音公司最佳论文奖和2013年美国摄影测量和遥感协会ERDAS最佳论文奖的获得者。他还因其在IEEE

JSTARS和20122014年IEEE Geoscience and Remote Sensing Letters的服务而获得了IEEE

GRSS的最佳审稿人奖。他的研究团队获得了IEEE Geoscience and Remote Sensing Society 2014 Data Fusion Contest的前三名, 他的学生近年来被选为IEEE International Geoscience and Remote Sensing Symposium学生论文竞赛的获奖者或入围者。



王树根 (M'03) 在中国武汉的武汉测绘学院获得了航空摄影测量的学士学位。1984, 1994年在武汉测绘科技大学获得摄影测量和遥感硕士学位, 1994年在武汉大学获得摄影测量和遥感博士学位。2003.

他目前是武汉大学遥感与信息工程学院的教授。他的主要研究兴趣包括: 挖掘-----。

空间分辨率遥感图像处理和计算机视觉。